



河北大学
HEBEI UNIVERSITY

密 级：

分 类 号：

学校代码：10075

学 号：20217014024

硕士学位论文

面向有限资源调度的多目标优化系统研究

学位申请人： 孟志航

指 导 教 师： 王祎丹 讲 师

曲 强 研究员

专业学位类别： 电子信息硕士

专业学位领域： 软件工程

院 系 名 称： 数学与信息科学学院

答 辩 日 期： 二〇二四年六月

Classified Index:

CODE: 10075

U.D.C.:

No. 20217014024

Thesis for the Degree of Master

Research on multi-objective optimization system for limited resource scheduling

Candidate: Zhihang Mg

Supervisor: Yidan Wang Lecture

Qiang Qu Researcher

Category of Professional Degree: Master of Engineering

Professional Degree Field: Software Engineering

College: College of Mathematics and

Information Science

Date of Oral Defense: June, 2024

摘要

多目标优化问题是一个古老且具有挑战性的领域。它涉及在众多可行方案中寻找最佳解决方案。多目标优化问题通常涉及多个优化目标和变量,并且需要满足一系列约束。随着高性能计算、数据挖掘和人工智能等技术的广泛应用和普及,越来越多的实际问题需要同时考虑多个相互关联的优化目标。多目标优化问题的研究日益受到重视,进行多目标优化算法具有重要的学术意义和实际价值。

本文着眼于利用智能优化算法及设计多目标调度模型解决实际多目标优化问题。以贵州乌江流域并网的沙沱水电站和思林水电站为研究对象,针对电力系统与航运系统的实际需求,建立了包含发电出力和航运通行量两个目标的多目标优化模型,并对水电站的下泄流量进行调度,从而实现水电站的高效发电和航运系统的顺利通行。该模型的建立有助于缓解电力系统的负荷压力,维护电网的稳定运行。主要工作和成果如下:

(1) 针对沙沱水电站由于电力负荷数据采集滞后导致的发电航运效益失衡问题,构建了集成负荷预测和多目标优化的混合智能调度模型。该模型首先应用预测算法预测电力负荷。再基于预测结果,调用改进的 Genetic Algorithm-Non-dominated Sorting Genetic Algorithm-II (GA-NSGA-II) 多目标优化算法对水电站下泄流量进行优化调度。以期在负荷数据缺失时实现并网水电站的高效调度,为提高发电和航运的综合效益提供新途径。

(2) 针对思林水电站面临的船舶实际到达时间与计划时间不一致及发电波动等挑战,提出一种集成储能机制、船舶到达时间预测和多目标优化的实时调度模型。通过对储能设备的充放电调节,实现平抑发电波动;基于预测船舶到站时间,确定调度决策的时间窗口;以发电量最大化和航运通过率最大化为目标。提出一种改进的 Non-dominated Sorting Beluga Whale Optimization (NSBWO) 混合智能算法,并利用 NSBWO 算法优化各时段的下泄流量,从而提高水电站的实时调度性能。

(3) 提出一种基于区块链技术的可信水电优化调度模型,构建了区块链+预测算法+调度优化一体化的分布式智能调度架构。该模型能最大限度保证电力负荷及用电数据的真实可靠性,确保科学高效的水电站调度运行;同时提高了数据处理的安全性、可追踪性和系统透明度。

关键词 多目标优化 智能优化算法 预测算法 水电站调度 区块链可信技术

Abstract

Multi-objective optimization problems are a longstanding and challenging field that involves searching for optimal solutions among numerous feasible alternatives. These problems typically entail multiple objective functions and variables, subject to a set of constraints. With the widespread application and popularization of high-performance computing, data mining, and artificial intelligence technologies, an increasing number of practical problems require the simultaneous consideration of multiple interrelated optimization objectives. Consequently, research on multi-objective optimization problems has garnered significant attention, as the development of multi-objective optimization algorithms holds crucial academic significance and practical value.

This study focuses on utilizing intelligent optimization algorithms and designing multi-objective scheduling models to address practical multi-objective optimization problems. Taking the Shatuo and Silin hydropower stations, which are interconnected in the Wujiang River Basin of Guizhou, as the research objects, a multi-objective optimization model is established based on the actual requirements of the power system and the shipping system. This model incorporates two objectives: power generation output and shipping traffic volume. The model aims to optimize the dispatching of the hydropower stations' discharge flow, thereby achieving efficient power generation and smooth operation of the shipping system. The establishment of this model contributes to alleviating the load pressure on the power system and maintaining the stable operation of the power grid. The main work and achievements are summarized as follows:

(1) In response to the issue of imbalanced benefits between power generation and shipping caused by the lag in power load data collection at the Shatuo hydropower station, a hybrid intelligent scheduling model integrating load forecasting and multi-objective optimization has been developed. This model first applies prediction algorithms to forecast power load. Subsequently, leveraging the predicted results, an improved version of the Genetic Algorithm-Non-dominated Sorting Genetic Algorithm-II (GA-NSGA-II) multi-objective optimization algorithm is employed to optimize the scheduling of the hydropower station's discharge flow. The objective is to achieve efficient scheduling of interconnected hydropower stations in the absence of load data and provide a novel approach to enhance the comprehensive benefits of power generation and shipping.

(2) To address the challenges faced by the Silin hydropower station, including inconsistent actual arrival times of vessels and fluctuating power generation, a real-time scheduling model integrating energy storage mechanisms, vessel arrival time prediction, and multi-objective optimization is proposed. By regulating the charging and discharging of energy storage devices, the model aims to mitigate power generation fluctuations. Based on predicted vessel arrival times, a time window for scheduling decisions is determined. The scheduling objectives are to maximize power generation and maximize shipping throughput. An improved version of the Non-dominated Sorting Beluga Whale Optimization (NSBWO) hybrid intelligent algorithm is presented, and the NSBWO algorithm is utilized to optimize the discharge flow rates for each time period, thereby improving the real-time scheduling performance of the hydropower station.

(3) This study proposes a trustworthy hydropower optimization scheduling model based on blockchain technology, which establishes a distributed intelligent scheduling architecture integrating blockchain, prediction algorithms, and scheduling optimization. This model aims to maximize the assurance of the authenticity and reliability of power load and electricity consumption data, ensuring the scientific and efficient operation of hydropower stations. Additionally, it enhances the security, traceability, and system transparency of data processing.

Keywords Multi-objective optimization Intelligent optimization algorithm Prediction algorithm Hydropower station scheduling Blockchain trusted technology

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 多目标优化问题研究现状.....	2
1.2.2 水电站优化调度研究现状.....	3
1.3 主要研究内容与章节安排	5
第二章 基础知识	6
2.1 传统方法的局限性.....	6
2.2 MOPS 问题相关定义.....	6
2.2.1 问题数学模型.....	6
2.2.2 支配关系	7
2.2.3 Pareto 最优解和最优前沿	8
2.3 多目标进化算法评价指标	8
第三章 基于预测算法的多目标调度优化模型	11
3.1 引言.....	11
3.2 背景和思路.....	11
3.3 电力负荷预测算法.....	12
3.3.1 SVR 模型	12
3.3.2 ARIMA 模型	13
3.3.3 CNN 模型	13
3.3.4 LSTM 模型	13
3.3.5 GRU 模型	14
3.3.6 CNN-LSTM 模型	14
3.3.7 CNN-GRU 模型	15
3.3.8 模型比较.....	15
3.4 沙沱水电站发电-航运多目标调度模型建立	16
3.4.1 航运效益影响因素分析.....	16
3.4.2 约束条件	17
3.4.3 建立目标函数.....	19
3.4.4 GA-NSGA-II 调度算法	19
3.5 沙沱水电站发电-航运多目标调度模型求解	21
3.5.1 实验介绍	21
3.5.2 实验目的	21
3.5.3 实验数据	22

3.5.4 实验过程.....	23
3.5.5 实验结果分析.....	31
3.6 本章小结.....	32
第四章 结合储能和预测的多目标实时调度优化模型	34
4.1 引言.....	34
4.2 背景和思路.....	34
4.3 船舶预计到达时间预测.....	35
4.4 船舶预计到达时间预测.....	37
4.4.1 约束条件.....	37
4.4.2 目标函数.....	37
4.4.3 NSBWO 优化算法	39
4.4.4 水电站实时调度模型.....	41
4.5 水电站实时调度模型实验分析	42
4.5.1 实验目的.....	42
4.5.2 实验过程.....	43
4.5.3 结果分析.....	45
4.6 本章小结.....	51
第五章 基于区块链可信技术的优化调度安全管理模型	52
5.1 引言.....	52
5.2 模型架构设计.....	53
5.2.1 总体架构设计.....	53
5.2.2 区块链监管模块架构.....	55
5.3 设计目标.....	57
5.3.1 安全需求.....	57
5.3.2 隐私需求.....	57
5.3.3 溯源需求.....	58
5.4 本章小结.....	58
第六章 总结与展望	59
6.1 工作总结.....	59
6.2 研究展望.....	60
参考文献.....	61

图目录

图 2-1	两目标 PARETO 最优前沿	8
图 3-1	CNN 模型图	13
图 3-2	LSTM 模型图	14
图 3-3	GRU 模型图	14
图 3-4	CNN-LSTM 模型图	15
图 3-5	CNN-GRU 模型图	15
图 3-6	通航保证率与下泄流量关系图.....	17
图 3-7	沙沱水电站水位走势图.....	18
图 3-8	沙沱水电站下泄流量走势图.....	18
图 3-9	GA-NSGA-II 调度算法流程图.....	21
图 3-10	SVR 模型实验结果图.....	23
图 3-11	ARIMA 模型实验结果图	25
图 3-12	CNN 模型实验结果图	25
图 3-13	LSTM 模型实验结果图.....	26
图 3-14	GRU 模型实验结果图	26
图 3-15	CNN-LSTM 模型实验结果图	27
图 3-16	CNN-GRU 模型实验结果图	27
图 3-17	预测负荷 GA-NSGA-II 调度实验图.....	28
图 3-18	实际负荷 GA-NSGA-II 调度实验图.....	29
图 3-19	实际负荷 NSGA-II 调度实验图.....	30
图 4-1	船舶预计到达时间解决方案流程图.....	36

图 4-2	XGBOOST 预测模型.....	37
图 4-3	NSBWO 算法模型流程图.....	41
图 4-4	调度模型流程图.....	42
图 4-5	决策变量编码图.....	45
图 4-6	CNN 预测结果图.....	46
图 4-7	RIDGE REGRESSION 预测结果图.....	46
图 4-8	LINEAR REGRESSION 实验结果图.....	46
图 4-9	XGBOOST 实验结果图.....	47
图 4-10	NSBWO 实验结果图.....	47
图 4-11	调度算法对比结果图.....	48
图 4-12	NSGA-II 实验结果图.....	49
图 4-13	GA-NSGA-II 算法对比结果图.....	49
图 4-14	REVA 实验结果图.....	49
图 4-15	NSGA-III 算法对比结果图.....	49
图 4-16	MOEA/D 实验结果图.....	50
图 5-1	区块链相关技术.....	53
图 5-2	模型总体架构图.....	54
图 5-3	区块链监管模块架构图.....	57

表目录

表 3-1	预测模型对比.....	16
表 3-2	影响航运效益的因素.....	17
表 3-3	实验环境配置表.....	21
表 3-4	沙沱水电站水位数据表.....	22
表 3-5	调度模型数据表.....	22
表 3-6	预测模型和评价指标.....	24
表 3-6	SVR 模型实验结果对比.....	24
表 3-7	沙沱水电站下泄流量调度结果表.....	30
表 3-8	预测算法评价指标结果表.....	31
表 3-9	调度目标函数值.....	32
表 3-10	调度模型指标对比.....	32
表 4-1	船舶通航数据表.....	43
表 4-2	模型参数设置.....	44
表 4-3	船舶预计到达时间.....	44
表 4-4	调度数据表.....	44
表 4-5	调度数据表.....	45
表 4-6	调度数据表.....	47
表 4-7	思林水电站调度实验下泄流量表.....	48
表 4-8	调度模型目标函数值对比表.....	50
表 4-9	调度模型评价指标对比表.....	50

第一章 绪论

1.1 研究背景及意义

如今前沿科学不断发展，各个领域面临的问题也日益复杂。例如，在工程领域，我们需要在资源有限的条件下设计出更有效、更可靠的系统；在金融领域，我们需要制定最佳的投资组合以最大化回报并降低风险。这些问题往往涉及大量的变量和约束条件，传统的方法往往难以找到全局最优解。因此，研究优化算法^[1]成为了解决这些问题的关键。

优化算法的研究对于提高效率和降低成本具有重要意义。在生产制造领域^[2]，通过优化生产计划和资源分配，可以实现生产过程的最大化效益；在交通运输领域^[2]，通过优化路径规划和车辆调度，可以减少能源消耗和减轻交通拥堵。优化算法的应用可以帮助我们发现隐藏的优化潜力，从而提高效率、节约资源和降低成本。优化算法的研究还对科学研究和工程设计具有推动作用。在科学研究中，优化算法可以帮助我们优化模型参数、拟合数据和发现规律^[4]；在工程设计中，优化算法可以帮助我们设计出更优化的结构、材料和系统。通过优化算法，我们可以加速科学研究的进程，推动技术创新和工程实践的发展。

当涉及到现实世界中的问题时，往往存在多个冲突的目标。例如，在工程设计中^[5]，我们可能需要同时考虑降成本、提性能以及减少环境影响。在供应链管理中，我们希望同时最小化库存成本、最大化客户满意度和最大程度地减少交货延迟。这些问题通常无法简化为单一的目标函数，因为目标之间存在相互制约和冲突。

在这种情况下研究者们开始关注多目标优化算法的研究，以寻求更全面和更有效的解决方案。通过多目标优化算法获得 Pareto 最优解^[6]，这些解决方案代表了问题空间中不同的权衡选择。这种多样性的解决方案可以帮助决策者更好地理解问题的复杂性，并根据具体需求做出决策。此外，多目标优化算法还能够帮助决策者发现新的解决方案和潜在的改进空间，促进创新和改进。

多目标优化算法还在决策支持系统中发挥着关键作用^[7]。决策者常常需要面对多个目标之间的权衡和取舍。通过多目标优化算法，我们可以提供一系列可行的解决方案，

这些方案代表了不同的目标权衡选择。决策者可以基于这些解决方案进行分析和比较,选择最符合实际需求的解决方案。这种决策支持能够提高决策的质量和效果,并帮助决策者在面对复杂问题时做出明智的决策。

综上所述,通过使用多目标优化算法我们可以更好地应对杂的现实挑战。因此,本研究以乌江航道上的沙沱、思林水电站为背景,以提高水电站的运行效益为目标,提出了两种多目标优化调度模型。

水利工程建设影响着现代社会的农业发展经济发展^[8],具有重大的战略性、基础性和社会公益性。因此,对并入电网的水电站^[9]的运行效益要求也越来越高。对于有航运任务的流域来说,发电和通航是一对相互制约、相互矛盾的调度目标,如果无法平衡调度通航需求和发电需求将会大大降低水电站的运行效益。水电站的发电-航运优化调度问题是工程系统中的一个经典问题,对于平衡航运和发电目标以及实现碳中和^[10]至关重要。

本研究工作在上述背景下,对乌江沙沱、思林水电站多目标优化调度问题展开深入研究。着重研究如何用现代智能优化算法提高并入电网的水电站的运行效益,提出沙沱、思林下游安全通航的水力学边界条件,分别建立了通航效益评价函数。并以发电、通航运行的水力联系为纽带,建立水电站发电目标与下游航运目标的多目标优化调度模型;进一步,提出基于白鲸优化算法和快速非支配排序算法改进的多目标白鲸优化算法,为并网水电站的实际调度运行提供一种切实可行的运行方法。最后为了确保在优化调度系统在实际运行过程中可能遇到安全风险、隐私风险以及透明性差的问题,提出了基于区块链可信技术的优化调度安全管理模型。

1.2 国内外研究现状

1.2.1 多目标优化问题研究现状

1772 年 FrankLin^[11]将多目标优化问题作为一个系统的研究问题提出。1896 年 V.Pareto 研究了多种优化问题,将这些问题演化成了 MOPs^[12]。V.Pareto 本人也被公认为多目标优化问题的鼻祖。

在过去的几十年内,多目标优化在社会中的作用不断增强,互联网经济、风险评估和大国外交等领域都需要运用多目标优化策略。同时,多目标优化的应用范围也逐

渐扩大到科研、物理天文和社会研究等领域。因此,越来越多的国内外学者开始投入到这一研究领域,为未来的研究奠定了坚实基础。他们的不懈努力产生了许多具有代表性的多目标优化算法,并被广泛地应用于科学研究和工程设计。但这些方法主要基于分层序列和基于适应度函数。它们沿用了单目标优化方法的核心内容,这种算法比较粗糙,在处理规模较大的应用案例时便显得力不能及。

20 世纪末,人们开始逐渐体会到进化算法^[13]的优势,因此开始考虑利用进化算法来解决 MOPs 问题。为了将理论知识与实践联系起来,研究者提出了多目标进化算法(MOEA)^[14],这是一种基于生物进化中自然选择和遗传机制的搜索算法。通过交叉、变异和选择实现对最优解的搜索,然后基于当前求得的一组解进行下一代进化,获取更优的解,直至求得最优解或达到终止条件。多目标优化算法主要经历了四个阶段。阶段一:MOEA 是通过简单结合进化算法和其他多目标算法来提高效率和扩展使用范围,从而增强其鲁棒性。阶段二:David Goldberg^[15]提出了使用 GA 实现多目标优化的技术,并采用小生境的思路。这种思路对 MOGA^[16]、NSGA^[17]和 MOPsO^[18]等多目标遗传算法的研究发展具有重要意义。阶段三的代表性特点是提出了保留精英个体思想。NSGA-II^[19]算法是这阶段优秀的代表算法之一。阶段四主要是在已有的基础上,提出了一些效率更高、鲁棒性更强的算法。对于多目标优化问题的研究越来越深入,出现了更多的新型多目标问题。为了解决这些问题,研究人员依据不同的方法参考点、交叉和变异策略以及基因编码方式,产生了各种以基本遗传算法为核心的算法。其中比较有代表性的有白鲸优化算法(Beluga Whale Optimization, BWO)^[20]。

然而,这些算法在效率、Pareto 最优解的分布、收敛性等方面存在一些缺陷和不足。大部分算法只能优化特定的多目标问题,并不具备通用性。在复杂的环境中,许多算法的精度和效率无法满足需求。因此,本文针对水电站并入电网的问题,使用了 GA 算法、NGSA-II 算法和 BWO 算法提出了两种多目标调度优化模型

1.2.2 水电站优化调度研究现状

对水电站多目标优化调度进行求解的方法主要有两种。一种是采用传统的权重法、惩罚函数法等将多目标问题转为单目标问题。另一种是采用现代智能优化算法或混合优化算法,这类方法往往计算的速度较快、精度较高,并且可以直接生成调度结果。

近年来,众多学者纷纷加入水电站多目标优化的队伍中。通过对相关工作的调研,

目前一些学者已经对水电站的实时调度问题进行了深入研究。Junjie Yang 等^[21]对层次多目标优化问题的粒子群优化算法及其在水电站优化运行中的应用进行了探索,以水电站峰能效益最大化和发电量最大化两个目标进行优化调度。Ieda G. Hidalgo 等^[22]结合进化算法和梯度算法提出了一种优化水电站短期运行的模型。Tianlong Jia 等^[23]提出了以日发电量最大化为目标考虑通航需求的调度模型,并使用遗传算法求得最优解。Xuejiao Meng 等^[24]以中国黄河下游小浪底和西夏园梯级水电站为背景,基于约束变换的种群初始化策略提出了一种改进的多目标布谷鸟搜索算法用来解决水能平衡问题。Ruiming Fang 等^[25]以中国岷江水口水电站为背景提出了水库生态保护和发电能力最大化的调度模型,并用改进的多目标粒子群优化算法进行求解。Carolina Gil Marcelino 等^[26]提出了一个有效的水电站发电调度数学模型,该模型使用珊瑚优化算法进行求解并在单个种群中使用不同的搜索操作符来进行优化。Zhong-Kai Feng 等^[27]以发电量最大为目标提出了一种新的多目标粒子群优化算法,该方法中引入逻辑映射使得初始种群均匀的分布在问题空间中,并且惯性权重和学习系数随迭代动态变化。C.G. Marcelino 等^[28]使用多目标进化群杂交算法解决了短期水力发电机组分配的问题并于其它优化进行了对比。Yubin Chen 等^[29]选择 NSGA-II、NSGA-III、RVEA 三种模型对水电站建立发电量与生态流量协调模型,并经过对比发现 NSGA-III 模型具有一定的优势。Peilin Wang 等^[30]以最小化多个电网的峰谷负荷差为目标函数,通过几种线性化策略,将原始的非线性非凸模型转换为标准的混合整数线性规划(MILP)公式。现有研究大多以发电量、效益最大化等为目标对调度时间段进行静态调度。鲜有人考虑到兼有航运效益和发电效益的水电站在调度过程中如何减少船舶实时过闸带来的影响,以及储能设备结合水电站发电量对稳定电网调峰的作用。

现有的研究关注点大都在如何优化水和能源、水和生态之间的关系。如何使发电效益最大化,以保证电力系统的稳定。很少去研究如何在满足电网电力负荷需求的情况下使得航运效益更高。没有考虑到电力负荷需求数据缺失给水电站优化调度带来的影响。如果无法获取准确可靠的负荷数据时,那么无论怎么优化调度都不能为水电站的优化调度提供可靠的技术支撑。同时,也鲜有人考虑既有航运需求又有发电需求的水电站,以及储能与水力发电相结合在稳定电网调峰方面的应用。

1.3 主要研究内容与章节安排

本文以贵州乌江航道上并入电网的水电站沙沱、思林为背景，提出了基于预测算法的多目标优化调度模型和基于储能和预测的多目标实时优化调度模型。论文由五个章节构成：

第一章 阐述了开展多目标优化算法研究的背景意义,梳理了水电站调度优化领域的研究现状及存在的主要挑战。最后概述了全文的主要研究内容和技术路线。

第二章 基础知识。介绍了与本研究相关的基础理论知识。

第三章 基于预测算法的多目标调度优化模型。

第四章 结合储能和预测的多目标实时调度优化模型。

第五章 结合区块链技术提高优化调度模型可信，提出了基于区块链可信技术的优化调度安全管理模型。

第六章 总结与展望。主要对本研究的工作和结果进行了总结，并对未来研究进行展望。

第二章 基础知识

2.1 传统方法的局限性

大多数传统多目标优化问题的解决方法是将问题转换为单目标优化问题来解决。所使用的方法核心也都是沿用单目标优化算法。经过多年的发展，传统多目标优化算法虽然也已取得了长足的进步，但依然存在几个方面的问题，如下所示：

(1) 传统方法通常在解空间中进行连续型参数的优化，但是对于离散型参数或混合型参数的优化问题^[31]，传统算法的搜索策略和操作符可能无法直接应用或产生有效的结果。

(2) 传统方法需要对问题的特点进行充分了解，对问题的形式和特征具有一定的依赖性。传统方法的通用性与普适性较差，在将多目标问题转化为单目标问题中涉及到一些参数，这些参数值的好坏取决于问题的先验知识、背景了解、特点等了解的多寡，针对不同的问题可能需要重新调整参数。

(3) 将多目标优化问题转化为单目标问题，一次只能获得一个解。因此，在实际求解过程中我们需要对参数进行不同的排列组合尝试，以便于获得一组非支配最优解。

(4) 传统方法在计算过程中需要进行大量的搜索和评估，尤其是在高维问题上，所以一般来说计算成本都很高。这可能限制了算法的实际应用，因为在实际问题中，计算资源和时间常常是有限的。

2.2 MOPs 问题相关定义

2.2.1 问题数学模型

MOPs^[32]是旨在求解一组均衡的能够同时满足 2 个或 3 个相互制约相互矛盾的目标的需求的解。通常 MOPs 的数学模型可以表述为：

$$\begin{cases} \min y = F(x) = (f_1(x), f_2(x), \dots, f_m(x)) \\ \text{s. t. } g_i(x) \leq 0, i = 1, 2, \dots, q \\ h_j(x) = 0, j = 1, 2, \dots, p \end{cases} \quad (2.1)$$

其中， $x = (x_1, \dots, x_n)$ 为 n 维的决策向量， X 为 n 维的决策空间，

$y = F(x) = (f_1(x), f_2(x), \dots, f_m(x))$ 为 m 维的目标向量, Y 为 m 维的目标空间。 $g_i(x)$ 表示 q 个不等式约束; $h_i(x)$ 表示 p 个等式约束。对于 $x \in X$, 如果 x 满足不等式约束 $g_i(x) \leq 0, i = 1, 2, \dots, q$ 和等式约束 $h_i(x) = 0, j = 1, 2, \dots, p$, 则称 x 为问题在 X 上的可行解。

在求解 MOPs 问题过程中, 对于不同的问题会有不同的子目标函数, 其优化目标也会不同。一般来说分为以下三种情况:

- (1) 所有的子目标函数都求最小值;
- (2) 所有的子目标函数都求最大值;
- (3) 一部分子目标函数求最小值, 另一部分求最大值。

在实际计算过程中为了求解方便, 通常会将所有的子目标函数转化为统一求解最大值或最小值。将求解目标函数最小化转为最大化, 表示为:

$$\min f_i(X) = -\max(-f_i(X)) \quad (2.2)$$

不等式:

$$g_i(x) \leq 0, i = 1, 2, \dots, k \quad (2.3)$$

转化为:

$$-g_i(x) \geq 0, i = 1, 2, \dots, k \quad (2.4)$$

通过这种巧妙的转化可以将求解不一致的多目标优化问题进行统一表示。

2.2.2 支配关系

支配关系^[33]分为决策变量之间的支配关系和目标空间之间的支配关系。

定义 2.1 (个体支配关系) 设 p 和 q 是种群 Pop 中的任意不同的两个个体, 我们称 p 支配 q , 需要满足下列两个条件。

1. p 的所有子目标都比 q 好, 即 $f_i(p) \leq f_i(q) (i = 1, 2, \dots, r)$;
2. p 至少存在一个子目标使得 p 比 q 好, 即 $\exists s \in \{1, 2, \dots, r\}$ 使 $f_s(p) < f_s(q)$ 。

r 为子目标数量。 p 为非支配的, q 为被支配的。表示为 $p \succ q$, “ \succ ”是支配关系。

定义 2.2 (目标空间支配关系) 设 $T = (t_1, \dots, t_n)$ 和 $I = (i_1, \dots, i_n)$ 是目标空间的两个向

量, 称 T 支配 I (即 $T \succ I$), 当且仅当 $t_k \leq i_k (k=1, 2, \dots, n)$; 且 $\exists l \in \{1, 2, \dots, r\}$, 使 $t_l < i_l$ 。

2.2.3 Pareto 最优解和最优前沿

定义 2.3 给定一个 MOPs 问题 $\min f(X)$, 将它最优解集定义为:

$$P^* = \{X^*\} = \{X \in \Omega \mid \neg \exists X' \in \Omega, f_j(X') \leq f_j(X) (j=1, 2, \dots, r)\} \quad (2.5)$$

当前进化种群最优解为非支配解 (non-dominated solution) [34]。在求解中, 针对每一代进化种群找寻当前的最佳解, 并使非支配集越来越接近理论最优, 即 $NDS_{Set}^* \subseteq \{X^*\}$, NDS_{Set}^* 即为我们最终要求得的解。

定义 2.4 给定一个 MOPs $\min f(X)$ 和最优解集 $\{X^*\}$, 它的最优边界定义为:

$$PF^* = \{f(X) = (f_1(X), f_2(X), \dots, f_r(X)) \mid X \in \{X^*\}\} \quad (2.6)$$

Pareto 最优解是通过将所有解的目标向量组合在一起而形成的非支配最优解集合。在图 2-1 中, 实线与虚线所围的区域成为搜索区域, 该区域内的点代表支配解。其中, 实线上的点都是 Pareto 最优解。




图 2-1 两目标 Pareto 最优前沿

2.3 多目标进化算法评价指标

一般来说我们在对多目标进化算法进行评价时[35], 主要通过以下三个方面进行分析:

(1) 算法解集的收敛性 (convergence), 表示算法解集与真实 Pareto 前沿的相似程度, 我们期望算法的解尽可能地接近 Pareto 前沿, 即解集与 PF 的距离尽可能小。

(2) 算法解集的均匀性 (uniformity/evenness), 反映了解集中个体分布的均匀程度, 我们希望分布的尽可能均匀。

(3) 算法解集的广泛性 (spread), 表示解集分布的广泛程度, 我们期望解集在 PF 上分布广泛且完整。

多目标优化领域的学者在研究过程中提出了许多衡量算法的指标, 主流的指标有: Hypervolume^[36]、Inverted General Distance (IGD)^[37]、Spacing^[38]等。

(1) 超体积指标 (Hypervolume, HV)

Hypervolume 最早是由 Zitzler 等人提出的, 表示非支配解集与参照点围成的区域空间立方体的体积。HV 定义为:

$$HV = \delta\left(\bigcup_{i=1}^{|S|} V_i\right) \quad (2.7)$$

其中, δ 代表 Lebesgue measure, $|S|$ 代表非支配解集的数量, V_i 代表参照点与求得的解集中的 i 个解构成的超体积。在计算过程中不需要知道真实 PF。HV 指标可以同时评价收敛性和多样性。然而, 在处理高维多目标优化问题时, 计算过程的复杂度较高。此外, 参考点会影响 HV 的准确性。

(2) 世代距离 (General Distance, GD) 以及反转世代距离 (Inverted General Distance, IGD)

代表算法求得的解集与真实 Pareto 前沿的逼近程度。GD 定义:

$$GD(P, P^*) = \frac{1}{|P|} \sqrt{\sum_{i=1}^{|P|} d_i^2} \quad (2.8)$$

其中, P 表示解集, $|P|$ 为解集的个体数量, d_i 表示 P 中第 i 个个体到 P^* 中最近个体的欧几里得距离值。GD 指标与 HV 指标相比计算量要小很多。但是在求解过程中要知道真实 PF 或实际的参考集, 而且 GD 指标只针对解集的收敛性进行评估, 缺乏一定的多样性。一般来说我们希望 GD 的值更小, 越小表明解集 P 就越接近真实 Pareto 解集。

IGD, 与 GD 指标相反表示真实 Pareto 前沿 P^* 与算法求解的解集 P 接近程度。

$$IGD(P, P^*) = \frac{1}{|P^*|} \sqrt{\sum_{i=1}^{|P^*|} d_i^2} \quad (2.9)$$

其中, d_i 表示 P^* 到 P 中解的最短欧几里得距离值。 IGD 指标与 GD 指标相比能够同时比较分析收敛性和多样性两个方面, 并且也具备着计算量小的优点。但同时也需要知道真实 PF 或实际的参考集。一般来说我们希望 IGD 的值更小, 越小表明真实 Pareto 解集 P^* 越接近解集 P , 算法的收敛性和多样性越好, 并且 P^* 中每个点在 P 中都有与之相对应的点来表示。

(3) Spacing 指标

Spacing 度量每个解到其他解的最小距离的标准差。Spacing 为:

$$Spacing(P) = \sqrt{\frac{1}{|P|-1} \sum_{i=1}^{|P|} (d'_i - d_i)^2} \quad (2.10)$$

其中, d_i 表示 P 中的第 i 个个体与其距离最近个体的欧几里得距离, d' 表示所有 d_i 的均值, $|P|$ 为解集 P 中个体总数量。Spacing 指标仅仅针对解集的均匀性进行度量, 没有考虑到解集的广泛性。一般来说我们希望 Spacing 的值更小, 越小表明解集 P 就越均匀。

第三章 基于预测算法的多目标调度优化模型

3.1 引言

优化调度模型的目标是通过分析历史数据并进行预测和优化,帮助做出有效的决策。如果历史数据缺失,模型将无法准确地评估和预测不同决策的结果。这可能导致模型提供的决策方案不够准确或不适用于实际情况,从而影响到优化调度的效果和结果。历史数据是对过去事件和情况的记录,通过对这些数据的分析,可以获得有关过去决策和结果的洞察。如果历史数据缺失,模型将无法获得完整的历史信息,从而限制了对问题的全面分析。这可能导致模型对未来情况的预测或优化决策的准确性下降。

同时,数据是构建和训练优化调度模型的基础。如果历史数据缺失或不完整,模型可能无法准确地捕捉到问题领域的特征和规律。这可能导致模型的建模过程不稳定,结果可能对输入数据的小变化非常敏感,从而降低模型的可靠性和鲁棒性。

因此,我们提出了一种将预测算法与现代智能优化调度算法相结合的模型,以解决数据缺失对优化调度模型的影响。并且我们以沙沱水电站运行中的调度需求为基础,将该模型应用于实际工程中。

3.2 背景和思路

水利工程的建设影响着现代社会的农业发展经济发展,具有重大的战略性、基础性和社会公益性^[39]。因此,对并入电网的水电站的运行效益要求也越来越高。对于有航运任务的流域,发电和通航是一对相互制约、相互矛盾的调度目标^[40],如果无法平衡调度通航需求和发电需求将会大大降低水电站的运行效益^[41]。水电站的发电-航运优化调度问题是工程系统中的一个经典问题,对于平衡航运和发电目标以及实现碳中和至关重要^[42]。

然而,在实际调度过程中,尤其是在及时获取电网电力负荷需求曲线方面面临着挑战。水电站获取电网电力负荷数据是一个复杂的过程^[43]。首先,电网运营商通常会组织电力市场交易来确定电力需求。然后,水电站与电网运营商建立联系进而确定自己的发电计划。在这个过程中经常会出现电力负荷数据不能及时获取的情况。水电站如果不能及时有效地获取电力负荷需求曲线,将直接影响水电站优化调度的结果,影

响下泄流量和水位，影响船舶航行质量。我们迫切需要切实有效的方法来解决这一问题。

要解决这类问题，首先需要将其抽象为一个带有约束条件的数学模型。比较主流的两种模型是发电量最大、发电效率最高的“以水换电”^[44]和耗水量最小、期末储能最多的“以电换水”^[45]，这两种模式都有复杂多样的约束条件。以往的研究对这一主题进行了广泛深入的探讨。然而，大多数学者的研究都集中在水电站效益、通航效益和生态影响方面。在无法及时获得电力负荷数据的情况下，如何对水电站进行科学的优化调度还没有系统的关注。当面临电力负荷缺失，现有的优化调度模型只能使用历史数据进行优化调度。

因此，提出了一种新颖的水力发电与航运联合调度模型，将预测算法与智能优化算法有机结合，在电网电力负荷数据无法及时获取的情况下，对水电站进行调度。它获取每个时段的下泄流量数据，既能满足电网发电需求，又能满足船舶航行需求。

3.3 电力负荷预测算法

为了解决水电站电力负荷数据获取不及时的问题，本研究利用历史数据对未来的电力负荷数据进行预测。由于贵州省沙沱水电站电力负荷数据只能在每晚 9:00 之后获取，及时获取这些信息往往是个问题。

针对这一问题，本文分析了历史电力负荷数据，并利用七种模型来预测未来电力负荷数据。对这些模型的准确性进行了比较，并选出了结果最优的模型。这七个模型涵盖了机器学习和深度学习中使用最广泛、最流行的模型。事实证明，它们都能很好地对时间序列数据进行预测，而且预测结果足够准确。

3.3.1 SVR 模型

支持向量回归（Support Vector Regression, SVR^[46]）属于有监督学习算法，需要数据具备一定的特征。SVR 主要用来处理分类问题也可以用来解决回归。擅长处理非线性不可分数据。针对本研究对电力负荷数据进行预测，旨在找到一个决策边界使得模型等于预测的负荷数据与真实的负荷数据之间的距离尽可能的小。由于本研究里电力负荷数据只有时间序列和电力负荷值，样本数据特征不足，因此，SVR 模型的泛化能力较弱，进行预测的效果可能不太理想。

3.3.2 ARIMA 模型

自回归积分移动平均法 (Auto Regressive Integrated Moving Average, ARIMA^[47]) 是时间序列预测模型。操作简单只需依赖自变量就能对自变量进行预测, 因此被广泛使用, 尤其适用于具有预测趋势和积分的时间序列数据。鉴于沙沱水电站的电力负荷数据是时间序列形式, 使用 ARIMA 模型可以很好地拟合数据曲线, 而且拟合曲线通常比较平滑。尽管 ARIMA 模型易于实施, 但它也有一些局限性, 如依赖于时间自相关性来求解, 以及需要根据过去和现在的训练数据来预测未来的变化。就本研究使用的电力负荷实验数据而言本研究使用的实验电力负荷数据可能与历史数据关系不大, 这可能会影响模型的有效性。

3.3.3 CNN 模型

卷积神经网络 (Convolutional Neural Networks, CNN^[48]) 一种卷积结构前反馈网络。最开始是针对二维图像进行开发的, 但同样可以用来对时间序列预测问题进行建模求解。由于实验电力负荷数据是由具有时间顺序的单个观测序列组成的一维的数据集, 我们选取 Conv1d 采用一维卷积网络, 并且在训练之前将数据进行归一化, 以加快模型运行的速度。在实验训练过程中, 我们将时间序列数据拆分为多个样本, 每个样本具有相同的时间步。在进行预测时, 需要模型从历史观测序列中学习规律并预测序列中下一个值。模型主要结构由卷积层、激活层、池化层构成, 具体的结构如图 3-1 所示。




图 3-1 CNN 模型图

3.3.4 LSTM 模型

长短期记忆网络模型 (Long short-term memory, LSTM^[49]) 主要解决梯度消失和梯度爆炸问题。我们在实验过程中的数据集是对电网负荷需求每分钟就进行一次统计, 因此数据量较大。使用 RNN 模型不能够记住长期依赖, LSTM 模型引入细胞状态“cell

state”记忆信息，遗忘门、输入门、输出门保持序列之间的通信，解决了这个问题。并且对单变量时间序列的预测有很好的效果，很适合用来对我们的电力负荷数据进行预测。LSTM 结构如图 3-2 所示。




图 3-2 LSTM 模型图

3.3.5 GRU 模型

门控循环单元 (Gate Recurrent Unit, GRU^[50]) 属于 RNN 的一个改进。GRU 与 LSTM 在处理实际问题的效果相差无几。但是 GRU 模型与 LSTM 模型相比，内部少了一个“控制门”，参数较少更容易训练。GRU 内部结构如图 3-3 所示。




图 3-3 GRU 模型图

3.3.6 CNN-LSTM 模型

卷积长短期记忆模型 CNN-LSTM 遵循编码器-解码器结构，使用 CNN 作为编码器，LSTM 作为解码器^[51]。CNN 能够从空间和时间数据中提取特征，增强数据并提高 LSTM 捕获时间特征的能力，从而提高电力负荷预测的准确性。

CNN-LSTM 时间预测模型的工作原理是首先输入时间序列数据集。然后，将每个

时刻的输入数据作为图像输入，CNN 模型处理每个时间步的输入数据并输出每个时间步的特征。然后，将扁平化的特征输入到 LSTM 层。LSTM 根据当前输入 $F(t)$ 和前一时间步的隐藏状态 $H(t-1)$ 计算每个时间步的当前隐藏状态 $H(t)$ 。接下来，可以在 LSTM 层之后添加全连接层，以进一步处理 LSTM 输出或进行预测。最后，输出层用于生成时序预测的结果。具体结构如图 3-4 所示。




图 3-4 CNN-LSTM 模型图

3.3.7 CNN-GRU 模型

卷积门控递归单元 CNN-GRU^[52]，与 CNN-LSTM 模型一样，我们也可以将 GRU 模型用作解码器。首先由 CNN 提取特征向量作为输入，然后 GRU 神经网络学习特征动态变化规律进行预测，从而提高预测的准确性。

CNN-GRU 时序预测模型的工作原理是首先输入时间序列数据集。然后，CNN 模型进行特征提取，将每个时刻的输入数据作为图片输入。然后，通过 Flatten 将 CNN 输出的特征扁平化为一个向量，作为 GRU 模型的输入。然后，将扁平化后的特征输入 GRU 层。GRU 会根据当前输入 $F(t)$ 和上一时间步的隐藏状态 $H(t-1)$ 计算每个时间步的当前隐藏状态 $H(t)$ 。接下来，可以在 GRU 层之后添加一个全连接层，用于进一步处理 GRU 的输出或进行预测。最后，输出层用于生成时序预测结果。具体结构如图 3-5 所示。




图 3-5 CNN-GRU 模型图

3.3.8 模型比较

上述七种模型在处理本研究中电力负荷预测问题时，各自都有优缺点，具体的如表 3-1 所示。

表 3-1 预测模型对比

模型	优点	缺点
SVR	实现简单，对异常值具有鲁棒性。	比较依赖数据特征，不适合大型数据
ARIMA	不需要外生变量，模型简单	数据的稳定性要求较高，只能用于线性问题
CNN	特征属性通过训练权重得到，可以处理高维数据	需要调参和大量的样本
LSTM	可以解决梯度消失或者爆炸的问题	内部结构相对比较复杂，训练效率比传统 RNN 算法低
GRU	与 LSTM 模型一样可以有效抑制梯度消失或爆炸	同传统 RNN 模型一样不可并行计算
CNN-LSTM	能从数据中提取有效的特征，并提高预测精度	当训练数据量不够庞大时，效果并不明显，模型搭建也相对复杂
CNN-GRU	同 CNN-LSTM 一样可以深入挖掘数据特征，提高数据质量。提高预测精度	当数据足够大时效果较为明显，同时模型建立时对数据类型的转换要求较高

3.4 沙沱水电站发电-航运多目标调度模型建立

沙沱水电站的发电量与通航效益都与水电站的下泄流量有关，并且二者相互制约、相互矛盾。如何进行调度使得二者达到最优，属于多目标优化中的 Pareto 问题^[53]。为了解决这个问题，本研究首先对影响航运效益的因素进行分析，然后探究沙沱水电站下泄流量与通航保证率之间的关系，接着对沙沱水电站实际调度过程中存在的约束条件进行讨论，最后建立发电目标函数与航运目标函数，利用 GA-NSGA-II 算法对问题进行求解。

3.4.1 航运效益影响因素分析

通过对影响航运的水文要素的研究发现，沙沱水电站下游航道的通航安全主要与下游航道的水位变化情况、流量、水流流速、水位单位时间内的变化率和下泄流量高度有关。其中，下游水位变化、日尾水位变化和当前流速与下泄流量有很大的相关性^[54]。下游流量的增减会影响下游水位和流量，而水位变化率和下游流量高度也与下泄流量有关。因此，影响下游航道安全的主要因素是下泄流量。表 3-2 列出了影响航道安全的具体因素。

表 3-2 影响航运效益的因素

影响因素	说明
下泄流量	为了满足通航条件，下泄流量需要满足一定范围
尾水水位日变幅	水位日变幅与下泄流量成正相关，由于下泄流量波动比较大，航道易产生非恒定流，所以水位日变幅也要满足一定的条件
尾水水位小时变幅	处于对航运安全的考虑，除了水位日变幅还要满足小时变幅的条件
下游水位变率	反应下游水位变化速率的指标
水流流速	船舶在通行时对于水流流速也有要求
下游河道比降	船舶顺行还是逆行，较大的河道比降都会影响船舶的安全

通过对沙沱水电站历史数据的分析，当沙沱水电站下泄流量为 0-200 m³/s 时，通航保证率大于 0.9；当下泄流量为 200-400 m³/s 时，通航保证率大于 0.8。随着下泄流量的增加，通航保证率降低。沙沱水电站具体下泄流量与通航保证率的关系如图 3-6 所示。




图 3-6 通航保证率与下泄流量关系图

3.4.2 约束条件

沙沱水电站调度系统约束条件如下：

水电站运行水位约束：为了保证水电站运行的稳定以及下游地区的安全，我们必须对水位高度有所限制：

$$Z_{min}^j \leq Z^j \leq Z_{max}^j \tag{3.1}$$

其中 Z^j 为电站在 j 时段的运行水位； Z_{max}^j 、 Z_{min}^j 分别为电站在 j 时段运行水位的上、下限。沙沱水电站水位走势如图 3-7 所示。




图 3-7 沙沱水电站水位走势图

水电站出库流量约束：出库流量与下游通航效益以及下游生态稳定息息相关，需要满足一定的条件：

$$Q_{min}^j \leq Q^j \leq Q_{max}^j \quad (3.2)$$

Q^j 为电站在 j 时段的下泄流量； Q_{max}^j 、 Q_{min}^j 分别为电站在 j 时段满足航运要求的最大、最小下泄流量。沙沱水电站流量走势如图 3-8 所示。




图 3-8 沙沱水电站下泄流量走势图

水电站时段出力约束：处于对水电站机组的保护以及维持电网调峰稳定，出力需要在一定范围内：

$$P_{min}^j \leq P^j \leq P_{max}^j \quad (3.3)$$

其中 P_{max}^j 、 P_{min}^j 分别为电站机组的最大、最小允许出力。

下游水位变率约束：下游水位不仅要满足最高最低水位，还要满足单位时间内的

水位变化值

$$\Delta Z_d \leq Z_{d_max} \quad (3.4)$$

$$\Delta Z_h \leq \Delta Z_{h_max} \quad (3.5)$$

$$Z_{15min} \leq Z_{15min_max} \quad (3.6)$$

ΔZ_d 、 ΔZ_h 、 Z_{15min} 分别为下游水位日变幅、小时变幅、十五分钟变幅 Z_{d_max} 、 ΔZ_{h_max} 、 Z_{15min_max} 为对应的最大值。

非负条件约束：变量都必须为非负数。

3.4.3 建立目标函数

乌江航道上的沙沱水电站承担着电网调峰任务，同时需要兼顾通航任务。为了实现水资源的最大利用率，给电网提供电能和出力，同时对船舶的通航影响最小。所以本文选择两个目标函数，发电调度目标函数和航运调度目标函数。

发电调度目标：给定水电站计算时段初、末水位，以水电站总发电量减去预测需求得发电量的值最小作为优化目标，如下所示：

$$\min f_1 = \left\{ 9.81 \sum_{j=1}^T P^j \Delta t - F_{\text{预测发电量}} \right\} = \left\{ 9.81 \sum_{j=1}^T H^j Q^j \Delta t - F_{\text{预测发电量}} \right\} \quad (3.7)$$

式中， f_1 为 T 时段内的总发电量；9.81 为出力系数； Δt 为计算时段间隔； P^j 、 H^j 和 Q^j 分别为第 j 个时段的出力、水头和发电引用流量。

航运调度目标：根据已知的电站下泄流量和通航保证率之间的关系，将通航保证率作为航道航运效益的评价指标。通航保证率的数值越大，表示航运效益越好。具体的航运调度函数如下：

$$\max f_2 = \frac{1}{T} \sum_{j=1}^T k_j (Q^j) \quad (3.8)$$

式中， f_2 航运调度目标函数； k_j 为第 j 时段通航保证率； Q^j 为第 j 时段下泄流量。

3.4.4 GA-NSGA-II 调度算法

遗传算法 GA 起源于自然界优胜劣汰的规律，对所需要解决的问题利用计算机进行

模拟求解。算法的主要流程步骤包括编码、设置适应度函数、选择、交叉、变异；并通过一定次数的迭代，直到求得最优解。GA 算法与传统的数学规划算法相比适用范围广、算法简单、易于并行化处理，但是全局搜索能力较弱。非支配排序遗传算法 NSGA-II 与 GA 算法的区别是在遗传操作执行前依据支配关系进行了排序分层。采取精英策略使得优秀的适应度高的个体有最高的概率保留下来。并且在优先度同级的个体中使用拥挤度计算，保证整体的多样性。同时与 NSGA 算法相比较降低了计算复杂度。

本文对沙沱水电站发电-航运多目标进行调度使用 GA-NSGA-II 算法进行求解。首先将沙沱水电站各时段的下泄流量进行编码，并使用 GA 算法得到的调度结果。随后将 GA 算法得到的结果作为先验知识，再利用 NSGA-II 算法进行二次求解最终得到满足发电目标和航运目标双优的调度方案。算法保留了 NSGA-II 个体的多样性、防止某些个体过度遗传致使提前收敛的优点，同时引入 GA 算法提高了 NSGA-II 算法优化结果的准确度。具体的算法流程图如图 3-9 所示。算法步骤如下：

步骤一：输入历史负荷数据，使用多种预测算法进行实验分析，得到预测精度最高的算法，接着对电力负荷进行预测。

步骤二：分析实际调度过程中存在的约束条件。

步骤三：在考虑约束条件的情况下，初始化各个时段的下泄流量值。

步骤四：使用 GA 算法生成一组较优解，并将 GA 产生的最优解作为 NSGA-II 的先验知识，并初始化种群。

步骤五：判断是否生成第一代调度结果，如果没有就通过非支配排序、选择、交叉、变异生成第一代子群。

步骤六：判断父、子种群合并是否成功，如果没有成功，则生成新的父代种群，并对新生成的种群进行选择、交叉、变异。

步骤七：判断迭代次数是否满足条件，如果没满足循环执行，直至满足条件。得到水电站各个时段的下泄流量数值最优的调度方案。

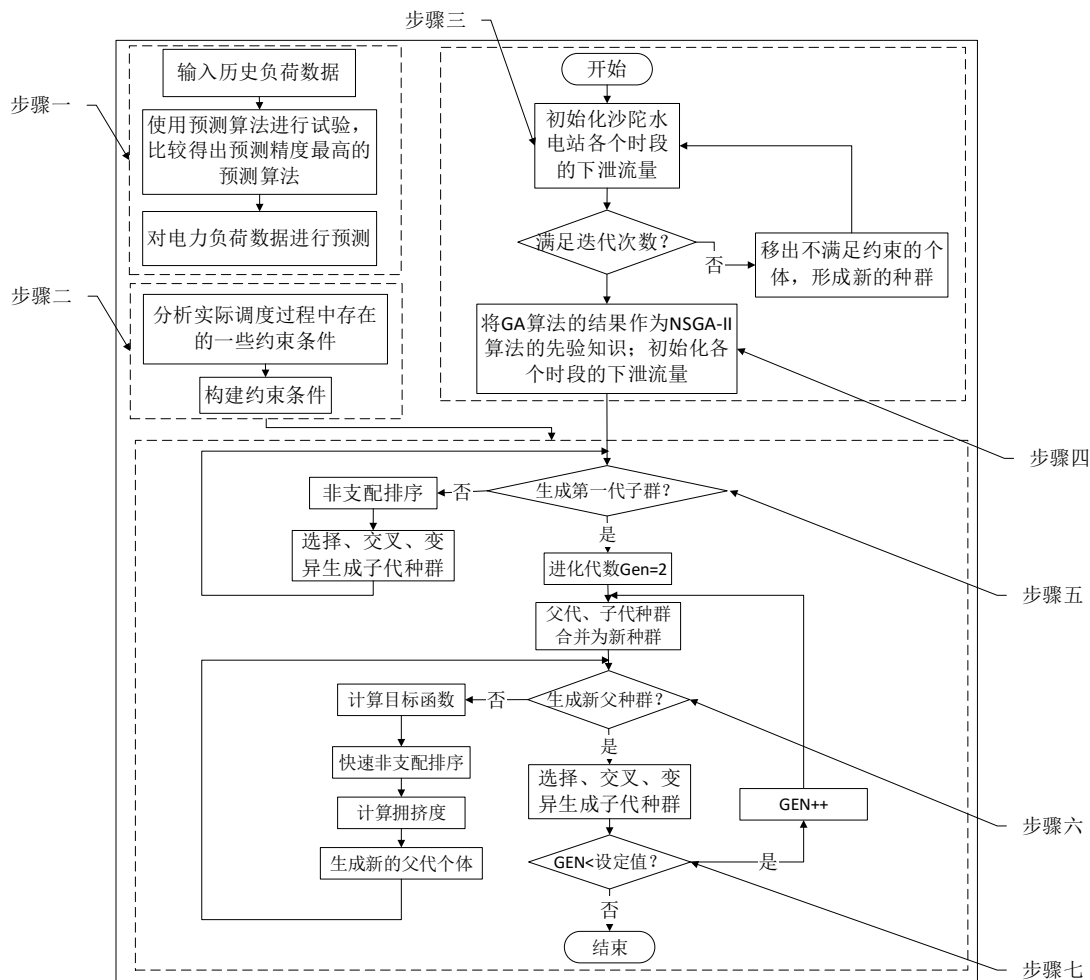


图 3-9 GA-NSGA-II 调度算法流程图

3.5 沙沱水电站发电-航运多目标调度模型求解

3.5.1 实验介绍

实验所用的软硬件环境如表 3-3 所示。

表 3-3 实验环境配置表

软硬件环境	配置
处理器	i7-12700H 2.70 GHz
内存	DDR5 16G 4800MHZ
硬盘	SAMSUNG MZVL2512HCJQ-00BL2
操作系统	Windows11
编程环境	Python3.9
开发语言	Python

3.5.2 实验目的

实验部分有两部分：电力负荷预测和多目标优化调度。在电力负荷预测方面，使

用了前面提到的七个预测模型来预测负荷值。在对结果进行比较后，选出准确率最高的预测算法。在多目标优化调度实验中，预测值和实际负荷值都被用作输入数据，GA-NSGA-II 算法的性能与 NSGA-II 算法的性能进行了比较。此外，还使用 NSGA-II 算法进行了实际负载数据实验，以比较与 GA-NSGA-II 算法的差异。

3.5.3 实验数据

我们共收集沙沱水电站 2021 年 10 月至 11 月的 51840 个数据，包括尾水位、流量、负荷和上游水位等信息。我们利用这些数据进行了电力负荷预测实验，如表 3-4 所示。

表 3-4 沙沱水电站水位数据表

2021 年 10 月 1 号 00:00—02:00				2021 年 10 月 1 号 02:00—04:00			
尾水水位 (m)	流量 (m ³ /s)	负荷 (KW)	上游水位 (m)	尾水水位 (m)	流量 (m ³ /s)	负荷 (KW)	上游水位 (m)
289.81	311.82	202.31	361.02	289.75	320.1	207.31	361.04
289.82	313.19	204.81	361.02	289.74	314.54	206.41	361.03
289.76	311.04	206.00	361.02	289.74	314.63	205.70	361.03
289.78	316.88	203.20	361.02	289.78	314.54	205.70	361.03
289.79	313.97	203.31	361.02	289.78	312.79	206.00	361.03
289.84	313.75	205.60	361.02	289.74	320.00	206.70	361.03
...
289.78	312.19	204.70	361.02	289.74	318.91	208.81	361.03

我们的数据集负荷以及流量都是一分钟更新一次，但在调度过程中，一分钟进行一次调度并不符合实际情况。所以我们将数据进行处理，每十五分钟计算一个平均值，一天 24 小时分 96 个数据进行调度实验。

数据分为电网负荷 Load、实时流量 Flow、流量上限 Flow_up、流量下限 Flow_down、通航保证率 G、水头 H 数据，示例如表 3-5 所示。

表 3-5 调度模型数据表

Load(KW)	Flow(m ³ /s)	Flow_down(m ³ /s)	Flow_up(m ³ /s)	通航保证率G	水头H(m)
199.2	332	327	337	0.96	0.065687
201.5	334.8	329.8	339.8	0.96	0.065752
357.5	619.1	614.1	624.1	0.84	0.062974
388.4	665.3	661.3	671.3	0.82	0.062413
410.8	702.3	697.3	707.3	0.80	0.559213
205.8	337	332	342	0.96	0.055074
...
250.5	336.7	331.7	341.7	0.96	0.055456

3.5.4 实验过程

由于收集到的数据只有时间戳和负荷属于时间序列数据，没有特征数据，所以我们将负荷数据向下移动 33% 生成一个新的列标签为 PLoad。将数据集的 0.33 划分为测试集，0.66 为训练集。选取线性核函数^[55]、高斯核函数^[56]、Sigmoid 核函数^[57]、多项式核函数^[58]进行试验。每个核函数做十次实验取各项指标的平均值。最终我们将测试集的前 1200 个真实值和预测值进行可视化输出。我们使用 MSE^[59]、MAE^[60]、RMSE^[61]、MAPE^[62]和 R^2 ^[63]指标来评价实验结果，评价指标的具体介绍如表 3-6 所示。实验结果如图 3-10 和表 3-7 所示，其中绿色的线条代表实际电力负荷，红色线条代表预测电力负荷。

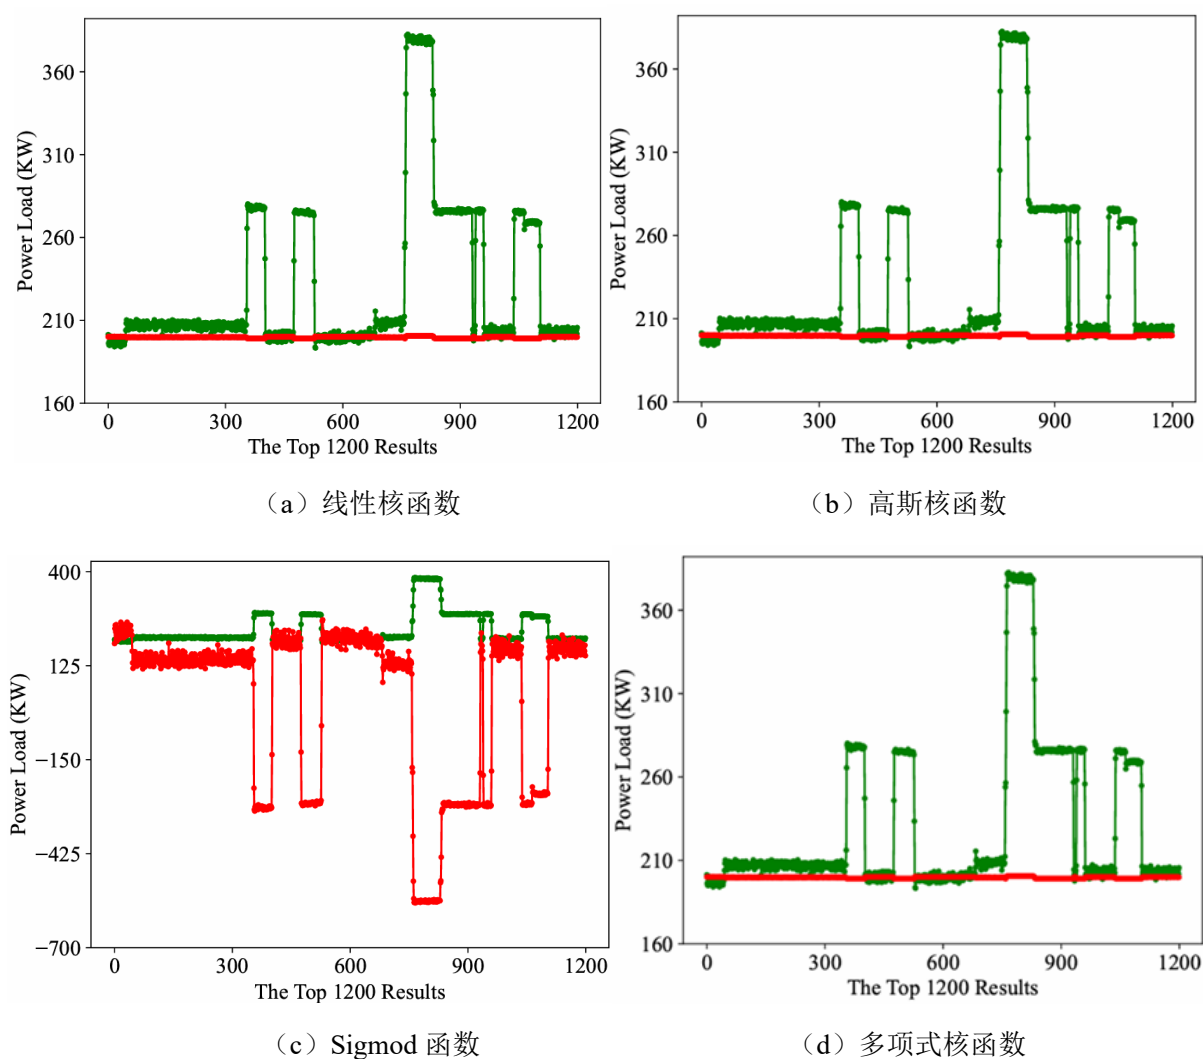


图 3-10 SVR 模型实验结果图

表 3-6 预测模型和评价指标

Performance Metrics	数学表达公式
均方误差 MSE: 评价数据的变化程度。MSE 的值越小, 预测模型的准确性越好。	$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
平均绝对误差 MAE: 主要用于机器学习和价格预测问题。它可以平衡和提高对观察值的置信度	$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $
均方根误差 RMSE: 观测值与实际值的偏差评估指标, 预测结果越好, RMSE 值越小。	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
平均绝对百分比误差 MAPE: 评判预测准确性, 范围[0,+∞), MAPE 值越小表面结果越好。	$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $
决定系数 R2: 是衡量模型拟合程度的一个量。这是一个比例公式。尺度区间为[0,1]。越接近 1, 模型的拟合度越高。	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

表 3-7 SVR 模型实验结果对比

SVR 模型核函数	MSE	MAE	RMSE	MAPE	R2
线性核函数	3111.8	19.8	55.7	9.8	-0.12278
高斯核函数	3113.9	19.8	55.8	9.8	-0.12353
Sigmoid 核函数	75072.5	130.9	273.9	85.7	-26.0868
多项式核函数	3085.7	19.6	55.5	9.8	-0.11336

ARIMA 模型在划分数据集的时候利用时间戳进行测试集、训练集的划分。2021-10-01 00:00 到 2021-10-28 00:00 期间的数据为训练集; 2021-10-29 00:00 到 2021-11-05 23: 59 的数据为测试集, ARIMA 中 order 的参数, 通过 ACF 图和 PACF 图拖尾进行选取, “P”“D”“Q”值分别为“2”“1”“2”。最终我们将测试集的前 1200 个真实值和预测值进行可视化输出, 其中实际电力负荷用绿线表示预测电力负荷用红线表示。如图 3-11 所示。预测数据与真实数据相差不大, 拟合效果较好, 具体的评价指标结果如表 3-9 所示。




图 3-11 ARIMA 模型实验结果图

CNN 模型将训练集划分为总数据的 1/3, test_size 为 0.33。在训练之前将数据进行归一化。模型由两层卷积层连接一层池化层接着连接一层全连接层。第一层卷积核的数目 filters 设为 8, 卷积核的时域窗长度 kernel_size 为 3, 激活函数选择“relu”, 第二层卷积核的数目 filters 设为 16, 卷积核的时域窗长度 kernel_size 为 3, 激活函数选择“relu”。池化层池化窗口 pool_size 为 2。迭代次数为 50 次, batch_size 梯度为 100, 进行训练, 最终我们将测试集的前 1200 个真实值和预测值进行反归一化并且可视化输出, 其中实际电力负荷用绿线表示, 预测电力负荷用红线表示, 得到的实验结果如图 3-12 所示。预测数据与真实数据相差不大, 拟合效果较好, 具体的评价指标结果如表 3-9 所示。




图 3-12 CNN 模型实验结果图

LSTM 模型将训练集划分为总数据的 1/3, test_size 为 0.33。首先连接两层 LSTM 层, 然后进行降维操作返回一个一维数组, 接着在连接两层 LSTM 层。Units 为 32 有四个神经元数量为 32 的前馈网络层。损失函数选择均方误差。最终我们将测试集的前 1200 个真实值和预测值进行可视化输出。其中实际电力负荷用绿线表示, 预测电力负荷用红线表示, 预测的结果如图 3-13 所示。预测数据与真实数据相差不大, 拟合效果较好, 具体的评价指标结果如表 3-9 所示。




图 3-13 LSTM 模型实验结果图

GRU 模型与 LSTM 模型类似，参数选择上与 LSTM 模型的选择也是一样。显示两层 GRU 层接着降到一维，然后在连接两层 GRU 层。损失函数也是均方误差。最终我们将测试集的前 1200 个真实值和预测值进行可视化输出。其中实际电力负荷用绿线表示，预测电力负荷用红线表示，预测的结果如图 3-14 所示。预测数据与真实数据相差不大，拟合效果较好，具体的评价指标结果如表 3-9 所示。




图 3-14 GRU 模型实验结果图

将 CNN 与 LSTM 和 GRU 模型融合进行电力负荷预测。各个模型的参数设置与之前的模型保持一致。最终我们将测试集的前 1200 个真实值和预测值进行可视化输出。其中实际电力负荷用绿线表示，预测电力负荷用红线表示，预测结果如图 3-15 和 3-16 所示。预测数据与真实数据相差不大，拟合效果较好，具体的评价指标结果如表 3-9 所示。




图 3-15 CNN-LSTM 模型实验结果图

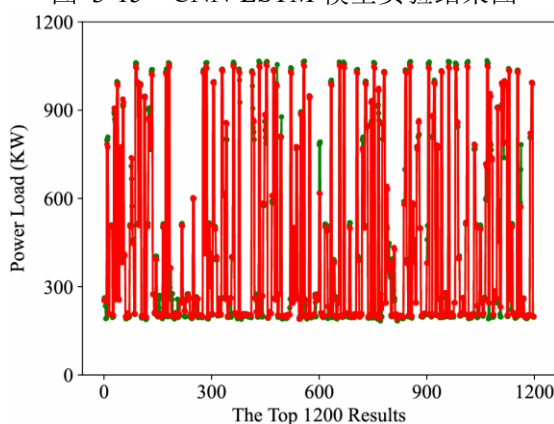


图 3-16 CNN-GRU 模型实验结果图

根据表 3-9 中的评价指标结果我们可以看出 GRU 与 CNN-GRU 模型的预测效果在七个预测模型中比较优秀。于是我们使用 CNN-GRU 模型对电力负荷数据进行预测，得到电力负荷数据。实验的过程中我们对预测负荷数据和实际负荷数据分别利用 NSGA-II 算法进行调度实验。调度的目标是让目标函数 $F1$ 最小、目标函数 $F2$ 的数值最大。并将两种实验结果进行比较。同时，我们使用 NSGA-II 算法进行实验作为对比。

我们选择沙沱水电站 11 月 1 号的数据作为实验数据。首先将数据每十五分钟取一个平均值即每十五分钟调度一次。并每六个小时进行一次模拟调度求解。利用 GANSGA-II 算法进行实验，第一层 GA 算法再求解的过程中参数 NIMD 设置为 800，最大进化代数 MAXGEN 设为 20，种群大小为 16000。第二层 NSGA-II 算法求解的过程中参数 NIMD 设置为 30，最大进化代数 MAXGEN 设为 50，种群大小为 1500。因为调度数据为实数，所以编码方式 Encoding 设置为 RI。

我们将实验结果可视化，图中的每一个红点都代表着一个种群（可行解）即符合条件的各个时段的下泄流量值。横坐标和纵坐标分别代表着每个种群对应目标函数 $F1$ 的数值和目标函数 $F2$ 得数值。由于调度的目标是使 $F1$ 发电效益最好， $F2$ 通航效益最

大，所以越靠近左上方的个体效果越好，调度的结果越好。其中，通过预测负荷调度的实验结果如图 3-17 所示，通过实际负荷调度的实验结果如图 3-18 所示，使用 NSGA-II 算法的实验结果如图 3-19 所示。我们从 GA-NSGA-II 模型中选择一个适应性较强的下泄流量调度结果进行展示，如表 3-8 所示。

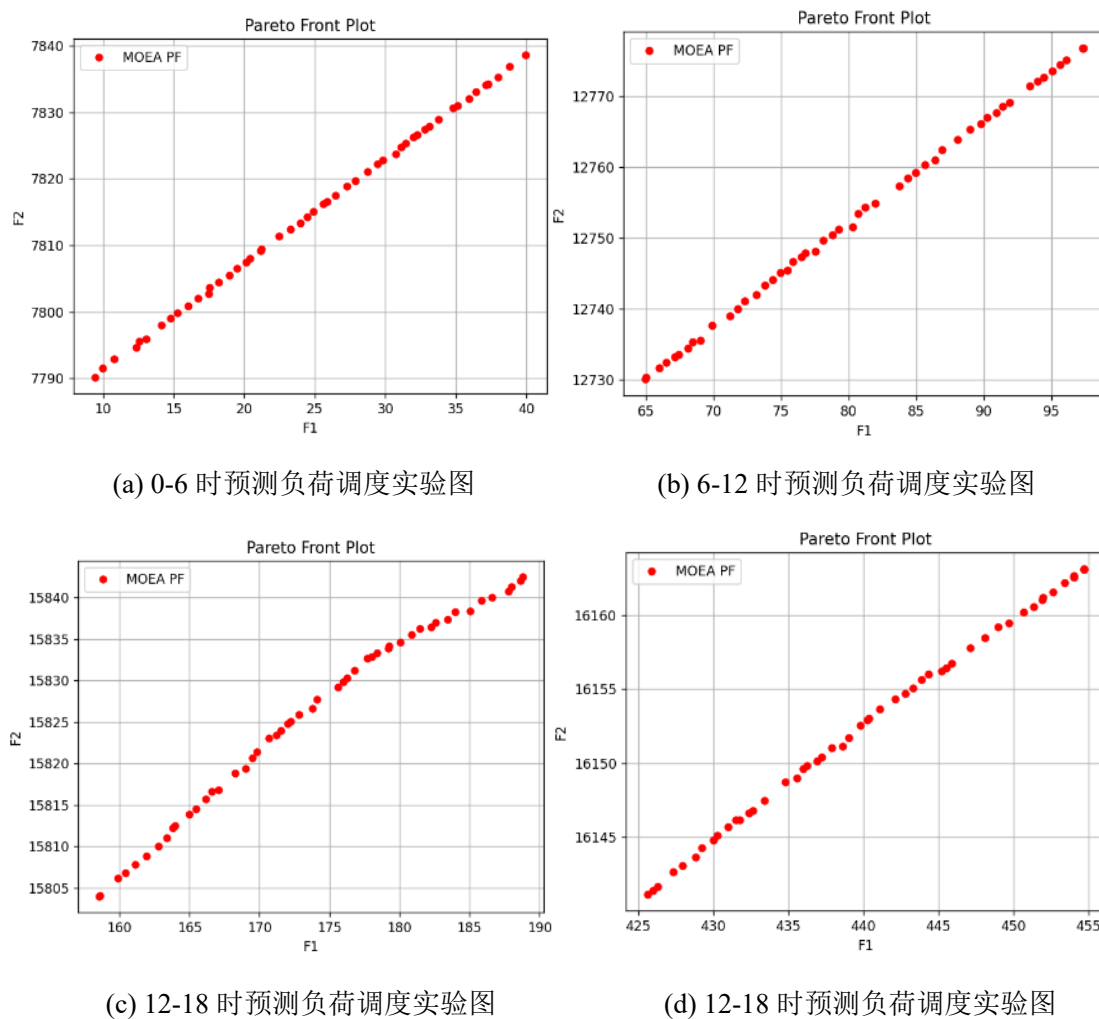





图 3-17 预测负荷 GA-NSGA-II 调度实验图




(a) 0-6 时实际负荷调度实验图



(b) 6-12 时实际负荷调度实验图

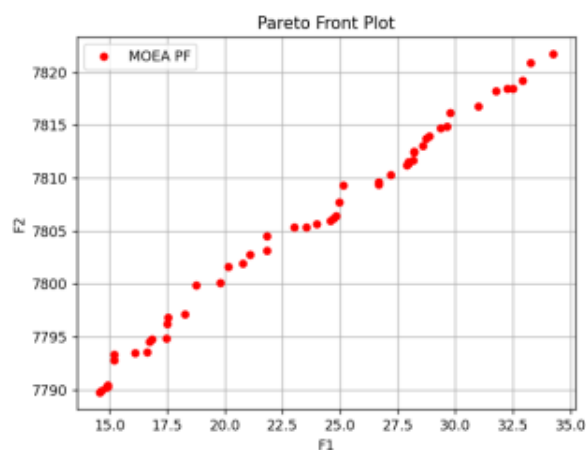


(c) 12-18 时实际负荷调度实验图




(d) 18-24 时实际负荷调度实验图

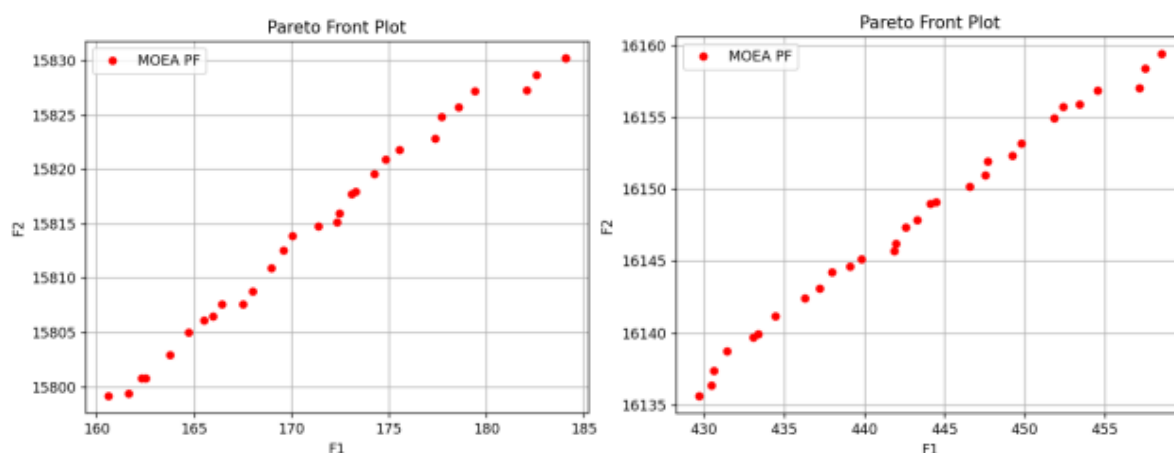
图 3-18 实际负荷 GA-NSGA-II 调度实验图



(a) 0-6 时预测负荷调度实验图



(b) 6-12 时预测负荷调度实验图



(c) 12-18 时预测负荷调度实验图

(d) 18-24 时预测负荷调度实验图

图 3-19 实际负荷 NSGA-II 调度实验图

表 3-8 沙沱水电站下泄流量调度结果表

时段起 始时刻	下泄流量 m^3/s		时段 起始 时刻	下泄流量 m^3/s		时段 起始 时刻	下泄流量 m^3/s		时段 起始 时刻	下泄流量 m^3/s	
	预测 负荷 结果	实际 负荷 结果		预测 负荷 结果	实际 负荷 结果		预测 负荷 结果	实际 负荷 结果		预测 负荷 结果	实际 负荷 结果
00:15	327	327	6:15	348	348	12:15	333	332	18:15	1503	1503
00:30	335	335	6:30	615	614	12:30	331	331	18:30	1498	1498
00:45	329	330	6:45	660	660	12:45	508	508	18:45	1403	1402
1:00	329	333	7:00	542	541	13:00	699	699	19:00	1638	1637
1:15	329	332	7:15	448	447	13:15	1365	1365	19:15	1667	1669
1:30	330	330	7:30	451	450	13:30	1414	1419	19:30	1672	1671
1:45	338	339	7:45	460	461	13:45	1106	1104	19:45	1821	1821
2:00	339	340	8:00	458	458	14:00	1160	1160	20:00	1876	1877
2:15	340	341	8:15	458	460	14:15	1232	1232	20:15	1869	1872
2:30	339	342	8:30	468	469	14:30	1378	1377	20:30	1872	1873
2:45	342	342	8:45	641	644	14:45	1370	1370	20:45	1871	1872
3:00	340	341	9:00	707	707	15:00	1432	1434	21:00	1871	1871
3:15	341	341	9:15	1271	1272	15:15	1606	1608	21:15	1876	1876
3:30	341	342	9:30	1143	1144	15:30	1869	1870	21:30	1552	1552
3:45	339	342	9:45	1197	1197	15:45	1860	1860	21:45	1381	1382
4:00	342	342	10:00	1389	1392	16:00	1866	1869	22:00	1580	1580
4:15	338	342	10:15	1195	1195	16:15	1741	1744	22:15	1879	1881
4:30	339	341	10:30	1006	1006	16:30	1882	1882	22:30	1682	1682
4:45	343	343	10:45	1008	1009	16:45	1878	1878	22:45	1604	1604
5:00	342	342	11:00	979	979	17:00	1619	1623	23:00	1397	1398
5:15	341	341	11:15	662	664	17:15	1441	1443	23:15	1109	1110
5:30	339	341	11:30	357	357	17:30	1419	1418	23:30	1108	1109
5:45	340	341	11:45	338	338	17:45	1388	1387	23:45	690	690

表 3-8 沙沱水电站下泄流量调度结果表（续）

时段	下泄	时段	下泄	时段	下泄	时段	下泄	时段	下泄	时段	下泄
起始	流量	起始	流量	起始	流量	起始	流量	起始	流量	起始	流量
时刻	m^3/s	时刻	m^3/s	时刻	m^3/s	时刻	m^3/s	时刻	m^3/s	时刻	m^3/s
6:00	339	340	12:00	339	340	18:00	1393	1393	24:00	341	341

3.5.5 实验结果分析

对模型进行训练后，输入测试数据，计算预测值。测试数据的预测值及其匹配的真实值将用于模型评估。在本文中，将通过五个回归模型的评价指标进行评估。其中， n 表示样本数， y_i 表示第 i 个样本的真实值， \hat{y}_i 表示第 i 个样本的预测值， \bar{y} 表示真实值的平均值。

由于 SVM 需要特征数据，我们的数据集不存在特征属性，利用 shift 函数生成了一个新的标签。所以 SVM 模型的表现很差。从表 3-7 的评价指标数据可以看出 SVM 采用多项式核函数进行预测的效果相对最好，所以这里我们 SVM 选择使用多项式核函数与其他模型进行对比。

表 3-9 展示了七种模型对电力负荷预测实验的评价指标数据。从数据可以看出表现比较好的是 GRU 模型和 CNN-GRU 组合模型，R2 指标达到了 0.99 以上。因此，我们选择 CNN-GRU 模型对水电站的电力负荷进行预测，并将其预测得到结果用于接下来的多目标优化调度实验中。

表 3-9 预测算法评价指标结果表

Performance Metrics	MSE	MAE	RMSE	MAPE	R2
SVM(poly)	3082.969	19.651	55.524	9.820	0.1123
ARIMA	37.158	2.629	6.0957	24.432	0.950
CNN	0.001182	0.0125	0.0344	3.138	0.985
GRU	0.000583	0.01021	0.0241	2.9532	0.993
LSTM	0.001095	0.0146	0.0331	3.8749	0.986
CNN-GRU	0.0006796	0.0116477	0.0260	3.1062	0.991
CNN-LSTM	0.0008309	0.0132209	0.0288	3.6110	0.9895

表 3-8 展示了使用预测负荷数据进行调度得到的下泄流量值和使用实际负荷数据进行调度得到的下泄流量值。可以看出两个实验得到的下泄流量数值相差无几，实际调度的过程中的差异可以忽略不计。一天内 96 次调度过程中二者的差距控制在了 5 以内。整体二者的目标函数值相差也在个位数。我们采取六个小时进行一次调度模拟，每六

个小时模拟调度的目标函数值如表 3-10 所示。

表 3-10 调度目标函数值

Time	预测负荷调度目标函数值		实际负荷调度目标函数值	
	目标函数F1	目标函数F2	目标函数F1	目标函数F2
00:00-06:00	14.19	7778.80	11.71	7793.83
06:00-12:00	66.79	12720.40	64.96	12726.78
12:00-18:00	160.49	15796.74	159.04	15800.03
18:00-24:00	428.74	16136.95	426.74	16141.11

我们通过实验比较了 NSGA-II 算法和 GA-NSGA-II 算法在优化水电站发电和航运双重目标方面的性能。实验使用实际负荷数据进行，目标是使目标函数 $F1$ 的值最小，目标函数 $F2$ 的值最大。实验结果表明，GA-NSGA-II 算法更适合我们的调度要求，因为它能找到更接近坐标轴左上方的解集。我们还使用 "超体积度量" (HV) 和 "间距" 评估了两种算法的性能。超体积度量 "用于测量解集与真实值之间的差异，即解集的收敛性。间距" 考虑了解集的内部分布，尤其是均匀性。HV 指标值越大，说明解集的收敛性越好，而 Spacing 指标值越小，说明解集越均匀。结果如表 3-11 所示。其中，GA-NSGA-II 算法的收敛性和均匀性优于 NSGA-II 算法。

表 3-11 调度模型指标对比

Time	GA-NSGA-II 的 HV 指标	NSGA-II 的 HV 指标	GA-NSGA-II 的 Spacing 指标	NSGA-II 的 Spacing 指标	GA-NSGA-II 的运行时间 (t/s)	NSGA-II 的运行时间 (t/s)
00:00-06:00	0.076	0.067	0.37	0.40	0.040s	0.13s
06:00-12:00	0.035	0.031	0.34	0.45	0.030s	0.13s
12:00-18:00	0.021	0.020	0.41	0.43	0.030s	0.13s
18:00-24:00	0.015	0.013	0.32	0.45	0.027s	0.13s

总之，我们的实验结果表明，GA-NSGA-II 算法是优化水电站发电和航运双重目标的较佳选择，并且可以应用于具有类似目标的其他调度问题。

3.6 本章小结

针对数据缺失对优化调度效果和结果的影响，本文提出了一种基于预测算法的多目标调度优化模型。并结合实际针对沙沱水电站电力负荷数据无法及时获取的问题，提出了基于电力负荷预测的水电站多目标优化模型。在该模型中，电力负荷预测模块使用了七种预测算法进行预测，经过比较最终选择了 CNN-GRU 预测算法。结果表明，该算法的拟合度约为 0.99。使用预测负荷数据进行调度与实际调度结果的差异不超过 5

(m^3/s), 满足实际调度要求。此外, 本研究还利用 GA-NSGA-II 算法对沙沱水电站进行了发电和通航双目标效益的优化调度, 四个调度时段的目标函数值、超量指标和间隔均优于 NSGA-II 算法。此外, 该基于预测机制的多目标调度模型适用性广, 并不局限于沙沱水电站的调度问题。只要稍加修改, 就可以用于其他水电站的调度和其他调度问题, 为解决数据不能及时获得的多目标调度问题提供了一种新的途径。水电站多目标优化的持续研究还将继续, 包括完成基于水电站、船舶申报航行计划、船舶实际到达时间和电网电力需求的水电站实时调度。

第四章 结合储能和预测的多目标实时调度优化模型

4.1 引言

谈到储能设备一般很少有人能与优化调度模型进行联系。但事实上，储能设备可以在负荷平衡、能量调度、频率调节、储能设备运营管理和应急响应等方面的优化调度中发挥作用。通过合理的调度策略和优化算法，可以充分利用储能设备的特性，提高优化系统的效率、可靠性和可持续性。

首先在涉及到电能优化调度问题时，储能设备能在低负荷时段储存电能，在高负荷时段释放电能，以实现负荷平衡。通过分析负荷曲线和需求预测，确定最佳的充放电策略，使储能设备在系统负荷波动较大时提供稳定的供电。其次，储能设备可以用于调度能源供应，特别是在可再生能源波动性较高的情况下。优化调度模型可以结合能源市场价格、可再生能源产生量和负荷需求，确定储能设备的充放电时机和策略，以最大程度地降低能源成本和平滑能源供应。最后，储能设备可以作为备用能源为系统提供应急能源，以确保系统在故障或突发事件发生时仍能提供可靠的能源供应。

因此，我们在上一章的基础上加入了储能设备构建了一种结合储能和预测的多目标实时调度优化模型。此外与上一章解决调度数据缺失问题不同，本章我们利用预测算法以实现实时调度的目标。并且我们以思林水电站运行中的调度需求为基础，将模型实际应用工程上。

4.2 背景和思路

建设新能源电力体系是实现碳中和目标的重要手段。新的运行环境下，并网水电站必须承担发电、航运、防洪等综合利用任务^[64]。水力发电是可再生能源，水循环过程是连续的。在配水网络中引入水力发电可以通过利用水流的动能来发电，从而实现能源的可持续利用。这有助于促进可持续发展的目标，减少对有限能源的依赖^[65]。这是双碳目标下新型电力体系建设的重要支撑，也是水资源高效利用的可靠保障。与此同时，水电站面临着强度更大、频率更高的电网调峰调频任务^[66]。水利和电力的双重需求也极大限制了水电站调度作业优化的空间，容易造成调度不平衡、效益不足、船舶航行不畅等问题。如何更好地协调电力调度和通航质量，进一步提高水电站联合优

化调度效益,减少船舶通过闸门的等待时间,是保证水电站效益的关键^[67]。

2022 年贵州省印发了《贵州乌江通航设施船舶实时过闸水位调度工作流程(试行)》的通知。旨在破解制约乌江航道存在的“通而不畅”的“卡点”、“赌点”问题,保障船舶安全、高效的通过沙沱、思林水电站通航设施,逐步实现北上“畅通长江”的战略目标。为此,制定并实施了“过闸申报+水位调度”的调度流程。试运行初期,思林水电站升船机实行提前一天申报过闸的规定。船舶运输企业向通航管理处报送过闸计划之后,再由通航管理处发给乌江公司集控中心。由于调度流程较为繁琐。此后,乌江公司又相继要求提前 2 天、3 天、4 天申报过闸,最后要求船舶提前一周申报。但水路运输受多梯级过闸时间和航道水位、货物装卸等因素影响较大,具有与其它运输方式不同的相对特殊性,船舶时隔一周后准点到达过闸的难度较大。因此,即使且准确的获取船舶到达时间是提高通航效率的关键。

为了提高并网水电站的运行效率,有效平衡航运和发电效益。考虑到实际调度过程中船舶实际到达时间与申报到达时间的差异,以及发电量的短缺或者过剩。我们提出一种新的多目标实时调度模型,利用预测算法、储能机制、智能优化算法来解决水电站发电和航运联合调度问题。

4.3 船舶预计到达时间预测

想要实现贵州乌江思林水电站“周水闸计划申报+日水闸计划控制+水闸实时调度”的组合模式。调度中心需要利用舰载北斗系^[68]、视频监控等技术手段来获取船舶的实时位置、速度等特征。并对船舶预计到港时间进行实时跟踪、分析和计算。

我们每六分钟收集一次带有时间戳的船舶航行数据。数据包括有船舶识别号(mmsi)、当前经纬度坐标(lat、lon)、航速(speed)、船舶类型(Ship_type)、出发地、目的地、目的地经纬度坐标(end_lat、end_lon)、实际出发时间、实际到达时间、是否到达目的地。

为了使预测结果更加准确,我们利用每个时间戳下的坐标来计算船舶行驶的距离。为了方便模型的建立和预测,我们将数据中的时间戳转化为日期类型。然后从时间戳中减去出发时间,即可得到船舶目前已经行驶的时间,并将已行驶的时间转化为以秒为单位。在划分数据集的过程中,我们随机划分了训练集和测试集,测试集的大小 test_size 选择 0.08。最后对历史数据进行训练并通过预测模型进行预测,流程如图 4-1

所示。

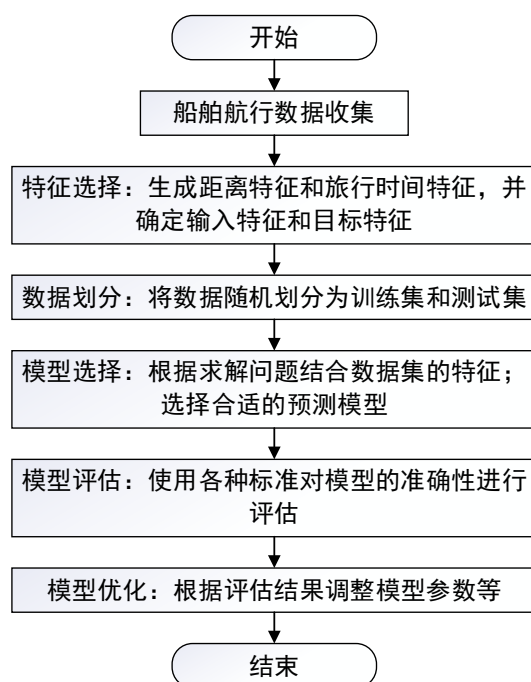


图 4-1 船舶预计到达时间解决方案流程图

我们采集的数据集中相邻数据的时间戳间隔较短，可以准确掌握船舶在行驶过程中的各种特征。在求解过程中，利用时间戳将估计的船舶到达时间转化为回归预测问题。极限梯度提升（XGBoost）^[69]在中小型数据集上高效工作，并且可以自适应地学习每个决策树的权重。它具有良好的泛化性能，广泛应用于数据科学领域。它可以有效解决船舶预计到达时间的预测问题。因此我们选择 XGBoost 模型进行预测。

XGBoost 是一种极限 boosting 树模型，也是一种基于决策树的集成梯度 boost 算法。由许多分类树和回归树（“弱学习器”）组成，每棵回归树使用的数据集是整个数据集，每棵树的生成可以看作是单个完整的回归树生成过程。树之间有顺序。前一棵回归树的结果会影响后一棵回归树的预测结果，即后一棵回归树在预测过程中会受到前一棵回归树偏差的影响。在每次迭代中，新的弱学习器根据先前模型的预测与真实值之间的差异来调整下一次迭代的模型。Boosting 通过将弱分类器的结果与预测值相加，然后下一个弱分类器会通过拟合误差函数到预测值的梯度（即预测值与实际值之间的误差），以继续减少残差，直到达到系统误差的要求。图 4-2 说明了该过程。

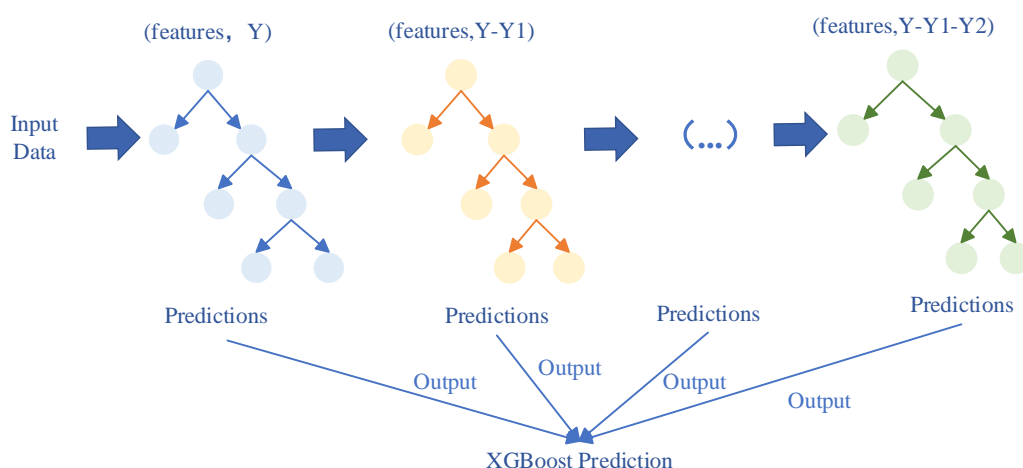


图 4-2 XGBoost 预测模型

4.4 船舶预计到达时间预测

思林水电站下游航道的航运安全与沙沱水电站类似，主要与水位变化、流量、水位变化率、下游水流高度有关。其中，下游水位和日水位变化、水流量与流量有很大的相关性。下游流量的增减影响下游水位和流量，而水位和下游流量变化率又与泄流量有关。因此，经过分析思林水电站与沙沱水电站相同，影响下游航道安全的主要因素是下泄流量。

4.4.1 约束条件

思林水电站存在的约束有水位约束、流量约束、机组出力约束、非负约束以及日水位变化约束、小时水位变化约束。这些与沙沱水电站约束一致。除此之外思林水电站还存在着船舶过闸约束。

船舶过闸约束：船舶在调度时段内通行过闸，需要保证电力负荷的供应保持不变。所以在船舶过闸的调度时段要与前一个调度时段内的下泄流量保持一致。同时。该时段的储能设备储备的电量加上该时段的发电量应该大于或等于该时段电网负荷需求。

设 $R_{StorageCapacity}^t$ 为 t 时刻的蓄电容量， $F_{Hydroelectricity}^t$ 为水电站 t 时的发电量， $F_{Electricitydemand}^t$ 作为 t 时刻的电网负载需求，因此我们有：

$$R_{StorageCapacity}^t + F_{Hydroelectricity}^t \geq F_{Electricitydemand}^t \quad (4.1)$$

4.4.2 目标函数

在研究中，我们考虑将水电站发出的电力存储到电网中，当水电站发出的电力不

能满足电网需求时，将存储系统放电。为了使水电站效益最大化，我们的目标是通过下游水流发电以满足电网需求。我们还旨在减少下游水流可能导致航运停止对船舶航行的负面影响。因此，在本文中，我们有两个目标，即发电和航运调度。

发电调度目标：调度时间段结束时，我们的目标是最大化总存储电量，总存储电量由每个时间段内的存储电量累加而成。每个时间段内的储能量是该时间段内的发电量加上所存储的电量，再减去该时间段内电网的负荷需求之和。水电站的发电量与泄流量有关，用“以水定电”的方法表示，如下所示。

第 t 时间段内存储的能量为：

$$F_t = \{9.81P^t \Delta t + R^{t-1} - F_{Electricitydemand}^t\} \quad (4.2)$$

$$R^{t-1} = 9.81 \sum_{j=1}^{t-1} (P^j \Delta t - F_{Electricitydemand}^j) \quad (4.3)$$

其中 P^t 表示水电站在 t 时刻的出力， R^{t-1} 表示 $t-1$ 时存储的电量， Δt 是计算出的时间间隔。 $F_{Electricitydemand}^t$ 表示 t 时刻的电网负载需求。

第 t 个时间段的输出力为：

$$P^t = H^t Q^t \quad (4.4)$$

其中 H^t 和 Q^t 分别是 t 时刻电站的功率输出、水头和发电引用流量。我们将初始存储能量设置为零，发电调度目标函数 $F1$ ：

$$MaxF_t = \{9.81 \sum_{j=1}^T H^j Q^j \Delta t - F_{Electricitydemand}^j\} \quad (4.5)$$

航运调度目标：将通航保证率作为航道航运效率的评价指标，其值越大越好运输效率。航运调度目标函数如下：

$$MaxF_2 = \frac{1}{T} \sum_{j=1}^T k_j(Q^j) \quad (4.6)$$

其中， k_j 为第 j 个时间段的导航保证率； Q^j 为第 j 时间段水电站的泄流量。

4.4.3 NSBWO 优化算法

多目标白鲸优化算法 NSBWO 结合了白鲸优化算法(Beluga Whale Optimization, BWO)与 NSGA-II 算法并且面向多目标优化调度的算法。采用非支配排序对生成的种群进行评价,在迭代产生子代的过程中采用白鲸优化算法进行生成。

白鲸优化算法模拟了白鲸游泳(全局勘探)、觅食(局部开发)、坠落三个行为。BWO 中三个阶段的跳跃取决于平衡因子 B_f , 其定义为

$$B_f = B_0(1 - T(2T_{\max})) \quad (4.7)$$

其中, T 是当前迭代次数, T_{\max} 是最大迭代次数, B_0 在(0,1)随机变化。当平衡因子 $B_f > 0.5$ 时为勘探阶段, 当 $B_f \leq 0.5$ 时为开发阶段。随着 T 的增加, B_f 范围从(0,1)减到(0,0.5), 开发阶段的概率不断增加。

探索阶段白鲸的位置更新如下:

$$X_{i,j}^{T+1} = X_{i,p_j}^T + (X_{r,p_1}^T - X_{i,p_j}^T)(1 + r_1)\sin(2\pi r_2), j = \text{even} \quad (4.8)$$

$$X_{i,j}^{T+1} = X_{i,p_j}^T + (X_{r,p_1}^T - X_{i,p_j}^T)(1 + r_1)\cos(2\pi r_2), j = \text{odd} \quad (4.9)$$

其中, T 是当前迭代次数, $X_{i,j}^{T+1}$ 是第 i 只白鲸在第 j 维上的新位置, $P_j(j=1,2,\dots,d)$ 是从 d 维中选择的随机整数, X_{i,p_j}^T 是第 i 条白鲸在 P_j 维度上的位置, X_{i,p_j}^T 和 X_{r,p_1}^T 分别是第 1 条和第 r 条白鲸的当前位置 (r 是随机选择的白鲸), 随机数 r_1 和 r_2 用于增强探索阶段的随机算子, r_1 和 r_2 是 (0,1) 的随机数, $\sin(2\pi r_2)$ 和 $\cos(2\pi r_2)$ 表示镜像白鲸的朝向水面。根据奇偶数选择的维数进行位置更新反映了白鲸的同步或镜像行为。

开发阶段位置更新如下:

$$X_i^{T+1} = r_3 X_{best}^T - r_4 X_i^T + C_1 L_F (X_r^T - X_i^T) \quad (4.10)$$

其中 T 是当前迭代次数, X_i^T 和 X_r^T 分别是第 i 条白鲸和随机白鲸的当前位置, X_i^{T+1} 是第 i 条白鲸的新位置, X_{best}^T 是最佳位置, r_3 和 r_4 是(0,1)之间的随机数, $C_1 = 2r_4(1 - T/T_{\max})$ 是衡量莱维飞行强度的随机跳跃强度。 L_F 是莱维飞行函数。

坠落阶段位置更新如下：

$$X_i^{T+1} = r_5 X_i^T - r_6 X_r^T + r_7 X_{step} \quad (4.11)$$

其中， r_5 、 r_6 和 r_7 是(0,1)之间的随机数， X_{step} 是步长，定义为：

$$X_{step} = (u_b - l_b) \exp(-C_2 T / T_{\max}) \quad (4.12)$$

其中， C_2 是阶跃因子($C_2 = 2W_f \times n$)， u_b 和 l_b 分别是变量的上下限。鲸鱼坠落概率 W_f 作为线性函数计算：

$$W_f = 0.1 - 0.05T / T_{\max} \quad (4.13)$$

BWO 是一种基于种群的优化算法，其灵感来自于自然界鲸鱼的习性。它根据自己的位置、食物和其他白鲸的位置进行更新。其次，BWO 可以通过鲸落跳出局部最优，并引入 Levy 飞行机制来提高收敛性。BWO 的探索能力是通过在整个搜索空间中不断扩展搜索代理来实现的，并且搜索轨迹聚集在全局最优周围，实现快速收敛。同时，BWO 的搜索历史表现出近似线性的搜索模式，以避免陷入局部最优并确保其全局收敛。BWO 的结果比遗传算法 (GA) [70]、粒子群优化 (PSO) [71]、灰狼算法 (GWO) [72]，引力搜索算法 (GSA) [73]在实际约束优化问题中的应用。因此，本文在解决水电站优化问题时引入基于 BWO 的 NSBWO 来优化航运和发电效率的调度。NSGA-II 中采用快速非支配排序、精英策略和拥挤度三种方法对群体进行筛选。BWO 探索、利用和下降的三个阶段用于生成后代亚群。与 NSGA-II 相比，保证了全局收敛性，提高了算法获得的可行解的数量和质量。具体的 NSBWO 算法流程如图 4-3 所示。

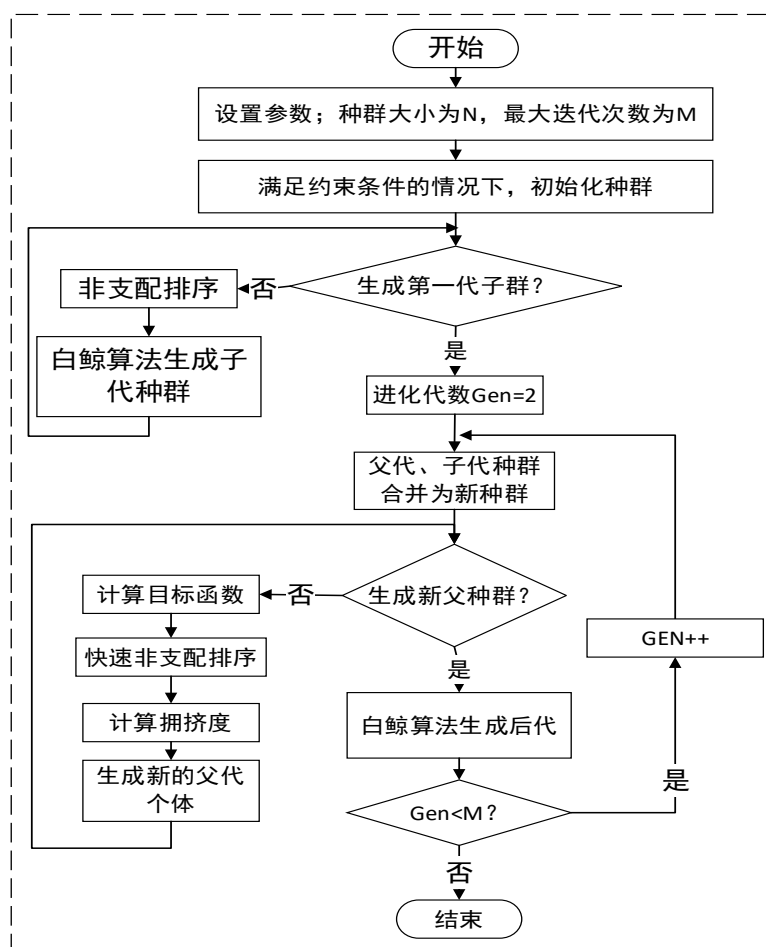


图 4-3 NSBWO 算法模型流程图

4.4.4 水电站实时调度模型

整个调度模型包含电力负荷、船舶预计到达时间、约束性修正、储能策略、调度优化五个部分。五个部分相辅相成共同构成了实时性多目标联合调度模型。具体的步骤如下：

步骤一：向电网系统请求调度时段内的电网负荷需求数据，并利用预测算法求出过闸船舶预计到达时间。

步骤二：将调度时段内下泄流量进行编码，编码位数等于调度次数。

步骤三：分析实际调度过程中存在的约束条件。

步骤四：判断该时刻是否有船舶通行，如果没有就正常调度发电，如果有下泄流量需要跟上一时刻保持一致，如果发电量不够需要储能机制进行放电。

步骤五：目标评估进行非支配分层排序。

步骤六：利用白鲸优化算法产生新的种群。

步骤七：进行非支配分层排序，计算拥挤距离。

步骤八：判断迭代次数是否满足条件，如果没满足循环执行，直至满足条件。得到水电站各个时段的下泄流量数值最优的调度方案。

调度模型的具体流程图如图 4-4 所示。

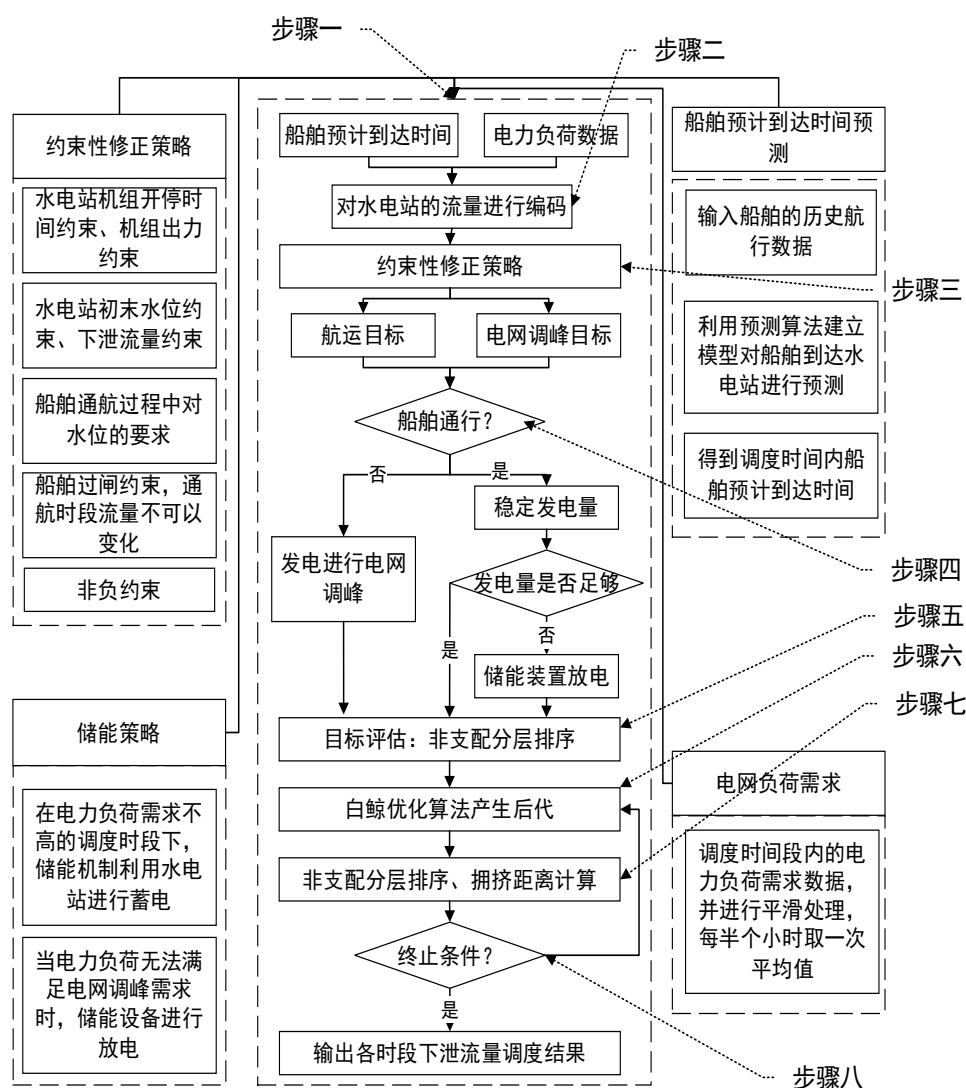


图 4-4 调度模型流程图

4.5 水电站实时调度模型实验分析

4.5.1 实验目的

利用 XGBoost 模型对到达时间进行预测，得到可通航船舶的实际到达时间。实现 XGBoost 模型来预测到达时间并得到可通航船舶的实际到达时间。还使用 Linear Regression、Ridge Regression 和 CNN 算法进行比较。在思林水电站实现了 NSBWO 算

法对各时间段的泄流量进行调度，并分析了该方法的可行性。并且还使用 NSGA-II、GA-NSGA-II、参考向量引导进化算法(RVEA)^[74]、NSGA-III、基于分解的多目标进化算法(MOEA/D)算法与所提出的算法进行实验比较。

4.5.2 实验过程

我们获取到 2021 年 10 月 1 号乌江航道上一艘货船的航行数据。数据展示了船舶从始发地到思林水电站的整个行驶状况。首先我们对数据进行清洗删除一些非特征列包括 num、时间戳。通行的船舶有很多种类包括普通货船、集装箱船、滚轮船、煤船、游船等。将每种船舶的类型初始化成一个数字，普通货船类型变量初始化为 1。并将特征属性下的离散类型进行热编码。根据时间戳和经纬度坐标计算出船舶在该时刻行驶的时间以及距离，如表 4-1 所示。

表 4-1 船舶通航数据表

Vessel _type	Start_lat	Start_lon	End_lat	End_lon	Lat	Lon	Speed	Distance	Duration
1	104.830	26.593	108.192	27.807	104.83	26.59	4.78	0.00	00:00:00
1	104.830	26.593	108.192	27.807	104.85	26.59	5.61	2.15037	0:05:19
1	104.830	26.593	108.192	27.807	104.87	26.60	3.96	4.30657	0:10:52
...
1	104.830	26.593	108.192	27.807	108.19	27.81	0.0	287.952	16:22:53

在预测船舶预计到达时间的过程中，我们选取了 9 个特征，分别是起止点的经纬度、船舶的实时经纬度、船舶的类型、船舶的航速。船舶和船舶行驶的距离作为输入特征，船舶的行驶时间作为目标特征。数据分为 0.92 训练集和 0.08 测试集。并利用下述公示将数据集映射到[0,1]进行归一化。

$$X^* = \frac{X - X_{Min}}{X_{Max} - X_{Min}} \quad (4.14)$$

在 XGBoost 模型调整参数的过程中使用网格搜索。对树的最大深度 max_depth、学习率 learning_rate、生成最大树的数目也是最大迭代次数 n_estimators 进行网格搜索。max_depth 设置为[7,9,11,13]，learning_rate 设置为[0.01,0.05,0.1]，n_estimators 设置为[500,1000]。每一种参数的组合都遍历一次，最终经过对比得到最佳的参数组合。具体的最优参数如表 4-2 所示。

表 4-2 模型参数设置

参数名称	参数值	说明
n_estimators	500	弱学习器的最大迭代次数
learning_rate	0.05	控制迭代速率，防止过拟合
gamma	0	节点分裂所需的最小损失函数下降值，参数值越大，算法越保守
max_depth	9	树的最大深度，值越大模型越复杂。可以通过这个值控制过拟合
alpha	1	权重的 L1 正则化项
lambda	0.5	权重的 L2 正则化项
subsample	1	控制对每棵树随机采样的比例
booster	gbtree	选择基分类器，指定上升模型，常用树或者线性模型

我们获取到的思林水电站相关数据集，相邻两行的下泄流量数据时间间隔为一分钟。但在水电站实际调度的过程中受机组开停的影响，一分钟进行一次调度不符合实际调度情况。所以我们将调度间隔选为半个小时，并将数据进行平滑化处理。每半小时对下泄流量求一次均值作为该调度时段内的下泄流量进行编码。

我们选取 2021 年 10 月 1 号当天 8:00 到 18:00 之间的数据进行实验。我们利用 XGBoost 算法求得的船舶预计到达时间如表 4-3 所示。

表 4-3 船舶预计到达时间

船名	船舶类型	航向	计划来源	预计到达时间
航电 608	普通货船	下行	APP 申报	2021-10-01 10:08:16
航电 605	普通货船	下行	APP 申报	2021-10-01 14:23:46
航电 636	普通货船	下行	AAP 申报	2021-10-01 16:52:54

水电站调度相关数据有下泄流量下限值 Flow_down、下泄流量上限值 Flow_up、电网负荷数据 Load、该时段是否有船舶通行如果有值为 1 否则为 0、通航保证率 k、水头 H。具体数据如表 4-4 所示。

表 4-4 调度数据表

Flow_down	Flow_up	Load	Ship_arrive	通航保证率 k	水头 H
438.6	478.6	275.2	0	0.90	0.06245
650.6	690.6	391.6	0	0.82	0.06279
1182.7	1222.7	673	1	0.60	0.06219
1270.4	1310.4	716.2	0	0.58	0.06286
1075.9	1115.9	632.4	0	0.66	0.06268
...
1365.8	1405.8	775	0	0.54	0.06242

通过 XGBoost 模型对船舶预计到达时间进行预测得到船舶到达时间，再结合电网

电力负荷数据结合多目标白鲸优化算法进行调度求解得到各个时间段的最优下泄流量。

首先对模型的一些参数进行设置，我们设置的目标函数包括发电效益最大和航运效益最高。所以目标函数的数量为 2、种群大小设置为 100、迭代最大次数为 200、交叉概率为 1。参数的具体设置如表 4-5 所示。我们调度思林水电站下泄流量的整个时间为 8:00 到 18:00，调度间隔为半个小时。所以我们进行编码的下泄流量个数为 20 并设置各个时间段的下泄流量上下限，如图 4-5 所示。




图 4-5 决策变量编码图

然后根据约束条件以及各个时段下泄流量限制进行初始化得到初始种群并进行非支配排序。利用白鲸优化算法产生后代，后代种群与父代种群进行合并得到新种群。对新种群进行非支配排序挑选出 100 个最优个体再次组成新种群。最后进行多次迭代直到达到最大迭代次数，得到发电航运双优的下泄流量解。

表 4-5 调度数据表

参数名称	参数数值
决策变量	20
种群大小	100
最大迭代次数	250
变异率	1/20
目标函数个数	2
交叉概率	1%

4.5.3 结果分析

我们使用相同的数据集，并且对数据集划分与 XGBoost 模型一致。利用 CNN、Ridge Regression、Linear Regression 模型进行对比实验。四种模型的预测结果如图 4-6—图 4-9 所示。其中红色曲线代表真实数据，蓝色曲线代表预测数据。由图像可以得出 XGboost 拟合的程度和 Linear Regression 接近，比 CNN 和 Ridge Regression 稍高。




图 4-6 CNN 预测结果图

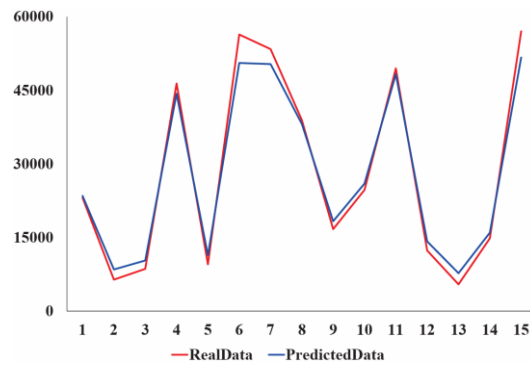


图 4-7 Ridge regression 预测结果图




图 4-8 Linear regression 实验结果图




图 4-9 XGBoost 实验结果图

使用历史数据训练模型后，将测试数据放入训练后的模型中并计算预测值。测试数据的预测值及其匹配的真实值用于模型评估。本文采用五种回归模型对评价指标进行评价，如表 4-6 所示。

由实验得出 XGBoost 模型在 MSE、MAE、RMSE、MAPE、R2 指标中都是最优的，其中 R2 拟合指标达到了 0.983。其次是 Linear regression 模型，优于 CNN 和 Ridge regression 模型。具体的指标如表 4-6 所示。

表 4-6 调度数据表

模型	MSE	MAE	RMSE	MAPE	R2
CNN	73201	30	35	47.3127	0.9614
Linear regression	1958	7	6	0.06386	0.9803
Ridge regression	64110	28	33	0.1525	0.9662
XGBoost	1799	5	5	0.04939	0.9831

我们将 NSBWO 实验结果可视化如图 4-10。图中的每个点代表一个种群即符合条件的各个时段的下泄流量值。横坐标和纵坐标分别代表着每个种群对应目标函数 F1 的数值和目标函数 F2 得数值。由于调度的目标是使 F1 发电效益最好，F2 通航效益最大，所以越靠近左上方的个体效果越好，调度的结果越好。




图 4-10 NSBWO 实验结果图

由图 5 可以得出目标函数值为 (917.321, 12429.1) (924.751, 12424.1) 的两个解集适应度最高。我们选取 (924.751, 12424.1) 这个解集进行展示, 如表 4-7 所示。表中 10:00-10:30、14:00-14:30、16:30-17:00 这三个时段有船舶过闸, 无法关停机组下泄流量需要同上一时刻保持一致。

表 4-7 思林水电站调度实验下泄流量表

时段	下泄流量 m^3/s	时段	下泄流量 m^3/s
08:00-08:30	455.7	13:00-13:30	1374.0
08:30-09:00	650.6	13:30-14:00	1108.3
09:00-09:30	1182.7	14:00-14:30	1108.3
09:30-10:00	1310.4	14:30-15:00	1376.9
10:00-10:30	1310.4	15:00-15:30	1714.3
10:30-11:00	969.0	15:30-16:00	1840
11:00-11:30	485.8	16:00-16:30	1788.2
11:30-12:00	337.8	16:30-17:00	1788.2
12:00-12:30	330.9	17:00-17:30	1406.1
12:30-13:00	627.1	17:30-18:00	1365.8

同时, 我们与 NSGA-II、GA-NSGA-II、RVEA、NSGA-III 和 MOEA/D 这五种算法进行比较, 结果如图 4-11。我们将不同算法求得的解用不同的符号进行标注。可以看出, 在种群数、约束条件和最大进化代数相同的情况下, NSBWO 调度获得的可行解数量明显多于其他 5 种优化算法。此外, NSBWO 求得的可行解由于其他方法的结果彼此非常接近, 我们将它们分别显示在图 4-12—图 4-15 中, 以便更好地理解每种方法。

需要注意的是, 为了可视化目的, 我们对图中的实际值进行了标准化。对于真实值, 图 4-12 中的每个 y 值应加上 12825.326。图 4-13 中的每个 x 值应加上 316.93792304。图 4-15 中的每个 x 值应添加 316.93792304。




图 4-11 调度算法对比结果图




图 4-12 NSGA-II 实验结果图




图 4-13 GA-NSGA-II 算法对比结果图




图 4-14 REVA 实验结果图




图 4-15 NSGA-III 算法对比结果图




图 4-16 MOEA/D 实验结果图

在每次调度实验中，我们选择最接近每张图右上角的解的目标函数 F1 和 F2 的值进行比较，结果见表 4-8。我们观察到 NSBWO 的 F2 值略小于表中的平均值，但是 F1 远大于平均值，因此 NSBWO 可以被认为是最好的。

表 4-8 调度模型目标函数值对比表

调度算法	目标函数 F1 值	目标函数 F2 值
NSBWO	924.751	12424.000
GA-NSGA-II	316.877	12825.326
NSGA-II	316.938	12825.327
NSGA-III	313.698	12825.308
RVEA	313.698	12653.400
MOEA/D	316.940	12827.000

接下来，我们评估调度算法的超体积(HV)、Spacing 和运行时指标。模型的结果显示在表 4-9 中。从运行时间来看，MOEA/D 的运行时间最长，其他模型的运行时间较小且接近。在 HV 上，NSBWO 算法的值最高，并且 NSBWO 得到的解集明显优于其他模型得到的解集。NSBWO 的 Spacing 最高，但由于其他模型获得的解集较少，并不意味着 NSBWO 的解集质量低于其他模型。

表 4-9 调度模型评价指标对比表

调度算法	运行时间	HV 指标	Spacing 指标
NSBWO	0.175	0.076	7.252
GA-NSGA-II	0.152	0.826×10^{-2}	0.262×10^{-5}
NSGA-II	0.144	0.820×10^{-2}	0.275×10^{-2}
NSGA-III	0.142	0.828×10^{-2}	0.301
RVEA	0.111	0.989×10^{-2}	0.917
MOEA/D	2.894	0.826×10^{-2}	0.000

4.6 本章小结

我们提出了结合储能和预测的多目标实时调度优化模型。首先，介绍了储能设备对于优化调度系统的意义。然后，考虑船舶实时通过和储能利用的调度策略来稳定水电站的发电。将该策略应用于中国乌江航道思林水电站的实际案例，显示了所提出解决方案的有效性。然而，该方法可以应用于其他地方。实验表明，XGBoost 算法实时预测船舶通过闸门的时间 R^2 为 0.98，与其他三种流行模型 CNN、Ridge Regression、Line Regression 和 Ridge Regression 相比具有竞争力。该预测方法提高了船舶过闸的等待时间，提高了水电站的电力调度效率。当水电站的发电量大于电网的需求时，储能装置就准备好储存能量。当小于电网需求时，储能被释放。本研究采用 NSBWO 算法结合 NSGA-II 和 BWO 对思林水电站泄洪流量进行优化。由此得出考虑航运和发电双重因素的水电站日常运行计划。在今后的工作中，我们将继续研究水电站的多目标优化问题。我们在实际调度过程中也会实时考虑对下游生态环境的影响。

第五章 基于区块链可信技术的优化调度安全管理模型

5.1 引言

近年来工业飞速发展进入了 4.0 阶段，现在制造业、工厂以及其他行业都需要可靠性更高、透明度更大的管理系统，用来应付处理日益复杂的工作生产环境。以优化调度系统^[75]为例，我们在调度过程中对于数据的可靠性和准确性要求很高。我们进行优化调度的依据就是实时数据以及历史数据。数据的可靠性决定着优化调度结果的有效性。目前，大部分管理系统^[76]包括调度系统采用的架构都是传统的云中心模式。这种管理系统存在诸多问题：

（1）传统管理系统依托于中心化的数据存储和控制机构，数据被篡改、欺诈和攻击的风险很多。中心化的系统容易受到单点故障和攻击的影响，数据的安全性和可信度有限。

（2）传统管理系统由中心机构控制和管理。数据的可靠性和一致性完全依赖于中心机构的诚信和运营能力。如果中心机构发生故障或出现数据错误，整个系统的可靠性和一致性将受到影响。

（3）传统管理系统中的数据操作通常缺乏透明度和可追溯性。用户往往无法直接查看和验证数据的来源和传输路径，这限制了对数据的可信度和可追溯性的保证。

（4）传统管理系统中通常存在许多中介机构。这些中间人的介入增加了成本和复杂性，并且可能引入人为错误和欺诈风险。

区块链技术^[77]，能够给调度优化管理系统提供新思路。利用分布式账本、智能合约、共识算法等技术手段，通过构建去中心化、可验证、不可篡改的系统，达到资源共享、信息透明、风险控制的目标，从而提高项目的增值能力。提高管理效率，降低成本和风险。如图 5-1 所示，通过区块链技术诸多可信技术^[78]能够提供安全的分布式管理方案，克服传统管理模式灵活性差、成本高昂、隐私风险等问题。

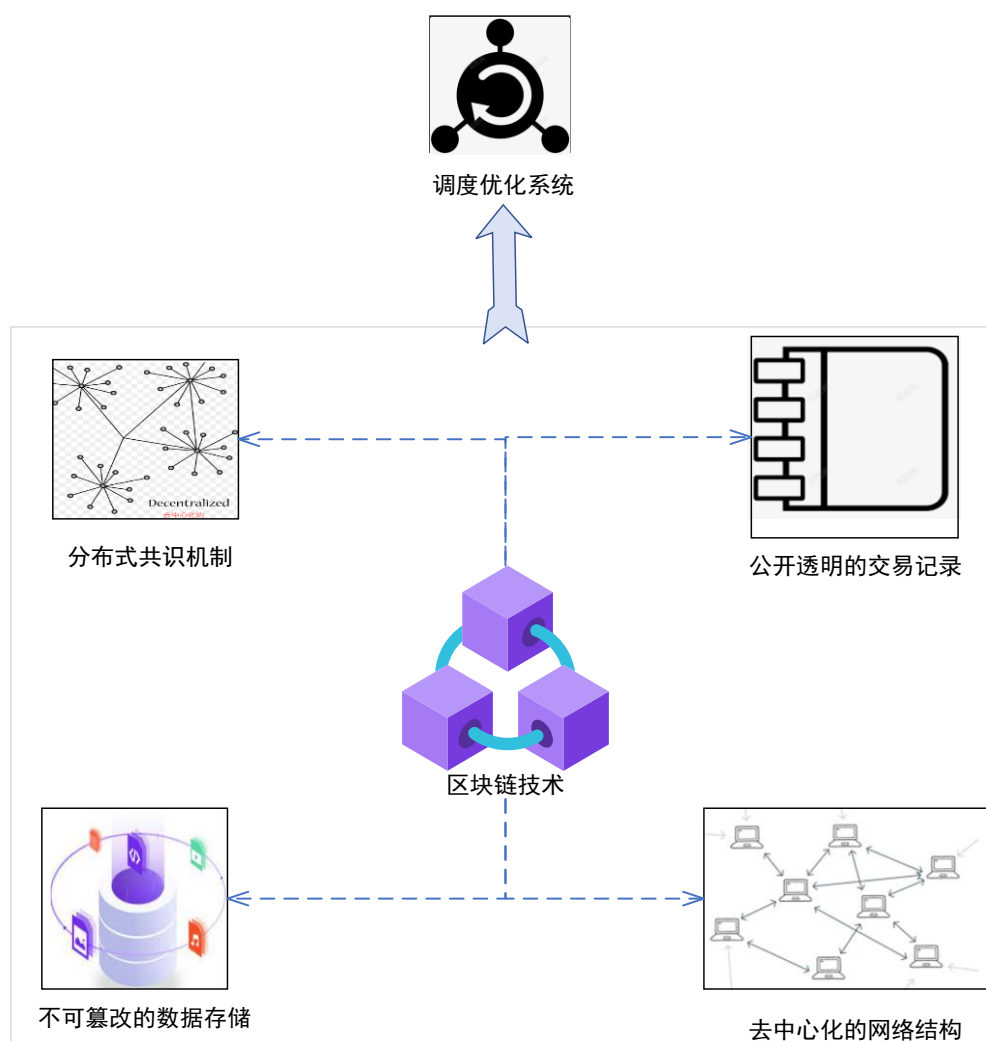


图 5-1 区块链相关技术

因此，本章以水电站下泄流量优化调度为背景提出一种新颖的基于区块链可信技术的优化调度安全管理模型，将区块链技术与优化调度系统相结合，利用区块链保证历史负荷数据的可靠性。

5.2 模型架构设计

5.2.1 总体架构设计

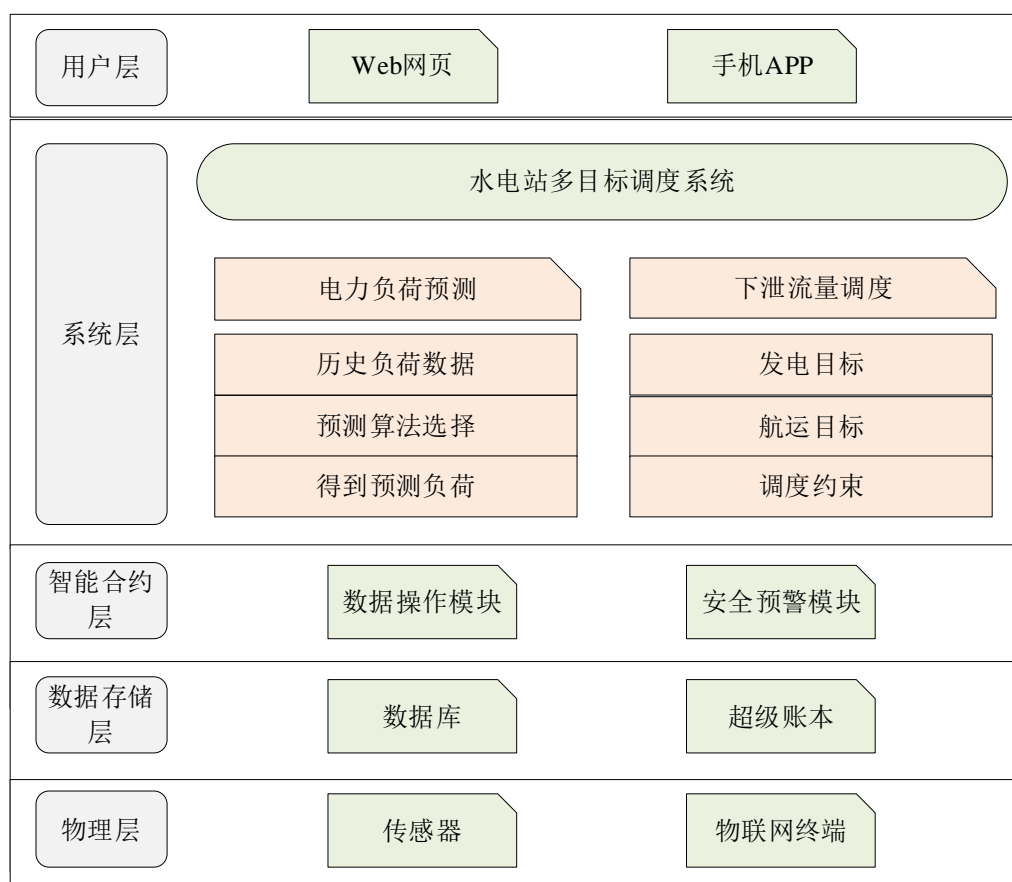


图 5-2 模型总体架构图

我们的水电站调度模型的总体框架如图 5-2 所示，总共包含五层：

第一层是物理层,它是区块链网络的最底层。该层主要由传感器和物联网终端组成,用于收集水位数据、调度数据和负荷数据。这些物联网设备并不属于区块链网络,它们只是用来与区块链网络进行数据上的交互。因此,我们的架构要求在区块链网络中所有设备都要有一个区别其他设备的唯一标识。为了实现这一点,我们使用公钥生成器和 SHA 散列函数生成公钥,并通过加密连接将它们相互关联起来。

第二层是数据存储层,它负责存储经过加密的区块数据,将数据记录到块体的 Merkle 树中,并对其进行 Hash 操作形成链式结构。为了确保系统整体的可用性和可靠性。在这种弱中心化的多中心结构下,每个节点都存储着完整的数据。通过共识算法,节点之间达成一致并保持数据的同步。当一个节点发生故障时,系统能够快速通过共识算法进行恢复,从而不会影响整个系统的可用性。这种设计方案能够提高系统的鲁棒性和可靠性,确保数据的安全存储和可靠访问。

第三层是智能合约层,智能合约层是一个关键组成部分,它包括数据操作模块和

安全预警模块。智能合约层利用区块链的智能合约技术，提供了数据操作和安全预警的功能。数据操作模块是智能合约层的核心组件之一。它基于预先设定的规则和条件，实现了对系统中的数据进行操作和管理的能力。通过智能合约，可以定义数据的访问权限、数据的更新和查询操作、数据的验证等功能。数据操作模块保证了数据的一致性、完整性和安全性，同时提供了透明的数据记录和追溯能力。安全预警模块是智能合约层的另一个重要组件。它通过监测系统中的数据 and 交易，实时检测潜在的安全风险和异常情况。安全预警模块可以设置预警规则和触发条件，一旦发现异常行为或安全威胁，将及时发送警报或触发相应的安全措施。这有助于及时发现和应对安全问题，保护系统和用户的利益。智能合约层的设计和实现需要考虑到系统的特定需求和业务逻辑。通过智能合约层，用户可以进行安全的数据操作，并在需要时接收到及时的安全预警信息。智能合约层的功能和特性可以根据系统的需求进行定制和扩展，以满足不同场景和应用的要求。总之，智能合约层在系统架构中扮演着重要的角色，提供了对数据的操作和管理功能，同时保障了系统的安全性和可靠性。

第四层是系统层，系统层主要包含两个模块，即电力负荷预测模块和下泄流量调度模块。电力负荷预测模块根据水电站历史负荷数据，预测未来调度时间内的电力负荷，用于下泄流量调度。下泄流量调度模块需要对水电站的发电目标函数和通航目标函数进行设计，并考虑实际调度过程中的调度约束。最后使用现代智能优化算法对下泄流量进行调度，得到符合实际需求的调度结果。

第五层是用户层，用户层包括 Web 网页和手机端 APP，为用户提供便捷的访问和使用方式。Web 网页提供在浏览器上访问系统的界面，用户可以通过常见的网页浏览器（如 Chrome、Firefox 等）访问系统功能。手机端 APP 则为用户提供在移动设备上使用系统的方式，用户可以通过安装在手机上的应用程序进行系统操作。通过 Web 网页和手机端 APP，用户可以方便地进行系统登录、数据查询等。

5.2.2 区块链监管模块架构

我们充分利用区块链的数据记录作用和可追溯性。将水电站运行过程中的一些数据例如：各个时段的发电量、各个时段的下泄流量以及各个时段的船舶通航率等；通过传感器、监控设备等实时采集。并将数据按照时间先后的顺序以区块链的形式记录和存储。

对每个数据块都进行加密并与前一个数据块的哈希值进行连接，形成数据链。数据链上的数据前后关系与实际时间顺序一致，以确保数据的完整性和真实。区块链上的数据是可追溯的，任何人都可以查看特定时间点的数据，了解水电站的运行情况、发电量等信息。

区块链利用密码学技术来保证数据的安全和隐私。限制参与者的访问和控制权。每个参与者都有一个唯一的标识符，并使用加密算法进行身份验证。在我们水电站调度系统使用智能合约来定义和执行权限和访问控制规则。只有获得授权的参与者才能访问特定数据并执行特定操作。参与者能使用自己的私钥进行数字签名，以证明自己的身份和数据的真实性。这确保了只有授权人员才能修改特定数据，并且可以追溯到特定参与者。

如果某个节点离线系统仍然可以正常运行，数据是可以恢复的。参与节点拥有写入和读取数据的权限，链上的区块可以同步，各节点可以共享调度信息。在保证数据真实性的前提下，实现调度信息的有效溯源，真正达到系统去中心化的效果。这些不同的节点具有不同的权限，因此每个节点都可以作为中心参与溯源过程。该模型实现的产品追溯全过程透明且不可篡改，解决了传统追溯的完整性问题。详细信息如图 5-3 所示。

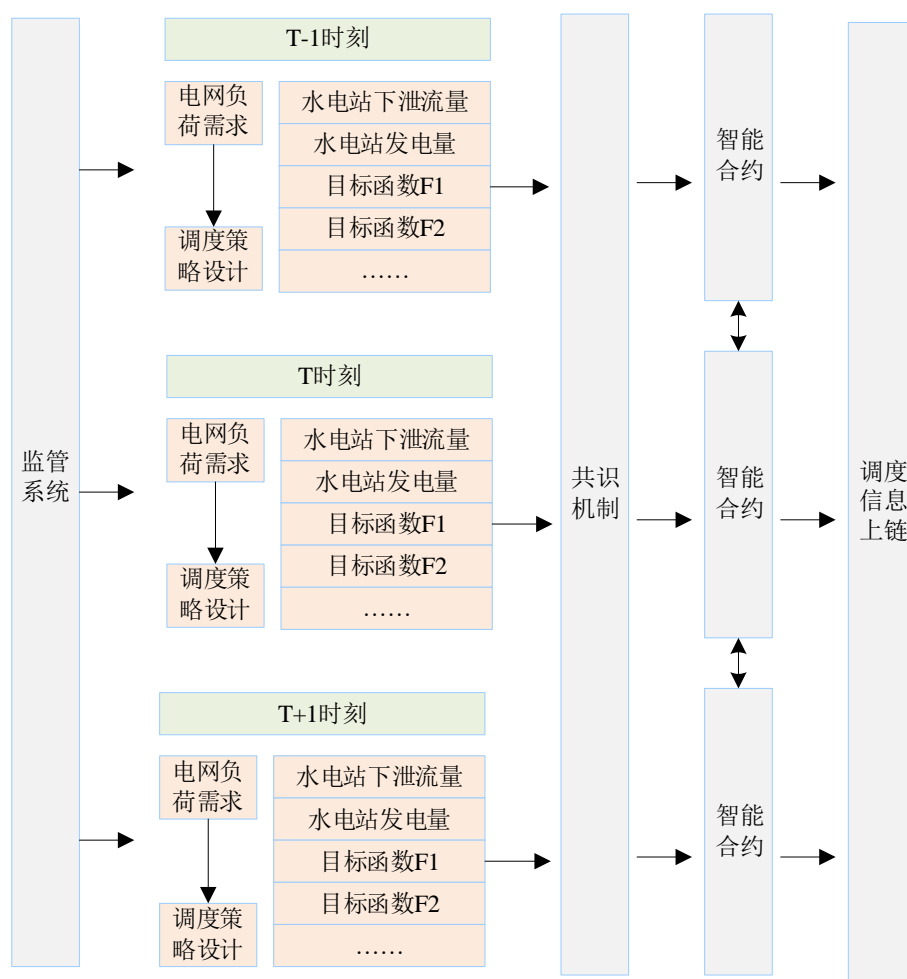


图 5-3 区块链监管模块架构图

5.3 设计目标

基于区块链可信技术的优化调度安全管理模型需要满足某些需求，如安全需求、隐私需求和溯源需求等。

5.3.1 安全需求

为了抵抗中间机构和人员操作失误，我们设计了一个模型，旨在通过区块链的去中心化网络和密码学来确保优化调度过程中目标变量的安全性。个体参与者使用公钥和私钥进行身份验证，并使用数字签名来上传数据，这些签名易于验证但无法伪造。数据被时间戳、加密以及共识算法保护，以确保其安全存储和复制在分布式节点中。

5.3.2 隐私需求

对于企业以及调控中心来说，与第三方公司或者机构交换数据很关键，因此需要对这些数据进行匿名化和隐私保护。同样，由工业物联网设备收集的数据也需要受到

保护，以防止未经授权的访问。为了保护隐私，区块链技术通过信息加密和安全通信，对保隐私起到了关键作用。注册后，每个实体会获得一个随机哈希地址，与其真实身份无关，从而满足隐私需求。

5.3.3 溯源需求

区块链保障了数据的完整性，因为一旦数据被记录就不可能被随意更改或删除。每个区块都包含了前一个区块的哈希值，形成了一个连续的结构，这种特性可以让溯源过程更加可靠和可信。区块链中的交易和数据记录都具有时间戳，记录了其发生的时间顺序。这使得在溯源过程中能够准确地追溯事件发生的先后顺序，帮助确定数据的来源和流转路径。基于上述机制和特性确保了溯源需求的满足。

5.4 本章小结

本章主要对基于区块链可信技术的优化调度安全管理模型进行了介绍。从宏观角度介绍了区块链如何与优化调度系统相结合，提高模型整体的可信力。首先，本节讨论了传统管理系统存在的问题和挑战；接着详细介绍了所提出系统的分层架构，并对区块链监管模块进行了深入剖析。最后，通过对各方需求的分析，确定了模型的设计目标。随着联盟区块链技术的快速发展和应用范围的不断扩大，基于区块链的管理应用系统备受关注。本章提出的安全模型为优化调度模型在实际运行过程中实现可靠性和透明性提供了强有力的支持。

第六章 总结与展望

6.1 工作总结

本章是作者在攻读硕士学位期间所做科研工作的一个总结，并对未来的工作进行了展望。

从上个世纪 60 年代开始就有大量学者研究多目标优化问题，取得了丰硕的成果。如今多目标优化算法也被广泛的运用到科研、工程以及生活中的方方面面。但随着科学技术得发展，日常生活中的问题也变得越来越复杂，对基于多目标优化的解决方案要求也越来越高。为了使多目标优化算法能够更好的解决实际问题，适用于求解各种复杂的优化问题。本文以乌江航道上并入电网的沙沱、思林水电站为研究背景，我们提出了两种多目标优化调度模型和一种基于区块链可信技术的优化调度安全管理模型。本文的具体工作主要集中在以下几个方面：

(1) 本研究提出了基于预测算法的多目标调度优化模型和结合储能和预测的多目标实时调度优化模型。并依据沙沱水电站和思林水电站各自的调度需求为背景运用到实际工程项目中，分别设计了以发电和通航为目标的多目标水电站调度优化模型。其中，结合沙沱水电站系统，构建了一种新的基于电力负荷预测与多目标优化的调度模型。模型将负荷预测和优化调度两个模块整合起来，确保水电站水调和电调的合作协同。结合思林水电站系统，构建了一种基于储能机制和船舶预计到达时间预测的多目标水电站实时调度模型。模型包括船舶预计达到时间预测模块，储能设备优化电网调峰模块以及发电通航双目标优化模块。

(2) 综合考虑水位、流量、机组出力等约束条件，针对沙沱、思林水电站分别提出各自的发电效益目标函数和通航效益目标函数，并建立了相应的数学模型。

(3) 同时使用多种神经网络和深度学习算法进行预测。并根据 MSE、MAE、RMSE、MAPE、R2 等评价指标，分析出精度最高、最适合用来预测沙沱水电站电力负荷的算法模型。并借助北斗卫星系统收集到的船舶航行时间对船舶预计到达时间进行预测。

(4) 以沙沱水电站为背景，采用改进的精英策略非支配排序遗传算法（GA-

NSGA-II) 求解水电站各时段下泄流量的编码调度方案, 并与 NSGA-II 比较了 HV、间隔、运行时间三个指标。最后, 实验表明, GA-NSGA-II 方案的适应性更强, 能获得更好的解决方案。

(5) 提出了改进的多目标白鲸优化算法 (NSBWO) 并且以思林水电站为背景, 使用 NSBWO 算法求解水电站下泄流量的编码调度方案, 并且与五种主流的调度算法进行对比。

(6) 利用区块链的可信技术, 提高了水电站调度管理系统可靠性和透明性。

6.2 研究展望

本文提出的两种多目标优化调度模型, 在人工智能算法和传统调度算法的基础上做了大量的理论研究和改进, 为多目标优化调度领域提供了一个解决实际问题的新思路。本文的理论研究工作及实验成果, 在一定程度上对实际应用具有指导意义。但仍存在一些不足:

(1) 沙沱、思林水电站优化问题在实际建模过程中可能存在更为复杂的约束条件以及外部影响因素。因此, 我们在建立数学模型中仅仅就水电站内部约束进行了讨论。未来, 我们可以针对外部因素包括天气、环境、季节等进行深入研究与讨论。

(2) 本文提出的 NSBWO 算法仅在思林水电站下泄流量调度优化问题上进行了探究, 其适用性与鲁棒性需要进一步考究。所以下一阶段我们会针对算法的效率问题和参数的设定上进行深入讨论和改进。

未来我们将继续对多目标优化领域的问题进行思考探究, 提升多目标优化算法的实用性。

参考文献

- [1] FENG Q, Li Q, QUAN W, et al. Overview of multiobjective particle swarm optimization algorithm[J]. Chinese Journal of Engineering, 2021, 43(6): 745-753.
- [2] 曾斌, 姚路, 胡炜, 等. 考虑不确定因素影响的保障任务调度算法[J]. 系统工程与电子技术, 2010, 38(3): 595-601.
- [3] 马祥丽, 马良, 张惠珍. 不确定车辆数的多约束车辆路径问题[J/OL]. 计算机工程与应用, 1-11[2024-01-13]<http://kns.cnki.net/kcms/detail/11.2127.tp.20240104.1625.046.html>.
- [4] 李宇, 刘玲, 薛铸. 基于群智能算法的土壤水分特征曲线模型参数优化[J]. 节水灌溉, 2023, (12): 57-65.
- [5] 刘景森, 杨杰, 李煜. 改进 JAYA 算法求解工程设计优化问题[J]. 电子学报, 2023, 51(09): 2469-2480.
- [6] 方红远, 邓玉梅, 董增川. 多目标水资源系统运行决策优化的遗传算法[J]. 水利学报, 2001, 9: 22-27.
- [7] 谢俊伟, 方峰, 彭冬亮, 等. 融合多属性决策和深度 Q 值网络的反导火力分配方法[J]. 电子与信息学报, 2022, 44(11): 3833-3841.
- [8] 毛浩明. 乡村振兴背景下农业水利工程管理研究[J]. 水上安全, 2023, (14): 160-162.
- [9] 周建平, 杜效鹄, 周兴波. 面向新型电力系统的水电发展战略研究[J]. 水力发电学报, 2022, 41(7): 106-115.
- [10] 高姗姗, 许彩慧. 双碳目标下中国产业链绿色低碳转型的思考[J/OL]. 河北经贸大学学报, 1-12[2024-01-13]<https://doi.org/10.14178/j.cnki.issn1007-2101.20240009.006>.
- [11] WILLIAM B. The Papers of Benjamin Franklin. New Haven[M]: Yale University Press, 1975.
- [12] Koopmans T C. Activity analysis of production and allocation[J]. Activity Analysis of Production and Allocation, 1951.
- [13] Michalewicz Z, Schoenauer M. Evolutionary algorithms for constrained parameter optimization problems[J]. Evolutionary computation, 1996, 4(1): 1-32.
- [14] Zhang Q, Li H. MOEA/D: A multiobjective evolutionary algorithm based on decomposition[J]. IEEE Transactions on evolutionary computation, 2007, 11(6): 712-731.
- [15] Sagun L, Trogdon T, LeCun Y. Universal halting times in optimization and machine learning[J]. Quarterly of Applied Mathematics, 2018, 76(2): 289-301.

- [16] Fonseca C M, Fleming P J. Genetic algorithms for multiobjective optimization: formulation and discussion and generalization[C]//Icga. 1993, 93(July): 416-423.
- [17] Srinivas N, Deb K. Multiobjective optimization using nondominated sorting in genetic algorithms[J]. Evolutionary computation, 1994, 2(3): 221-248.
- [18] Coello C A C, Lechuga M S. MOPSO: A proposal for multiple objective particle swarm optimization[C]//Proceedings of the 2002 Congress on Evolutionary Computation. CEC'02 (Cat. No. 02TH8600). IEEE, 2002, 2: 1051-1056.
- [19] Yusoff Y, Ngadiman M S, Zain A M. Overview of NSGA-II for optimizing machining process parameters[J]. Procedia Engineering, 2011, 15: 3978-3983.
- [20] Zhong C, Li G, Meng Z. Beluga whale optimization: A novel nature-inspired metaheuristic algorithm[J]. Knowledge-Based Systems, 2022, 251: 109215.
- [21] Yang J. A New Particle Swarm Optimization Algorithm to Hierarchy Multi-objective Optimization Problems and Its Application in Optimal Operation of Hydropower Stations[J]. J. Comput., 2012, 7(8): 2039-2046.
- [22] Hidalgo I G, Correia P B, Arnold F J, et al. Hybrid model for short-term scheduling of hydropower systems[J]. Journal of Water Resources Planning and Management, 2015, 141(3): 04014062.
- [23] Jia T, Zhou J, Liu X. A daily power generation optimized operation method of hydropower stations with the navigation demands considered[C]//MATEC Web of Conferences. EDP Sciences, 2018, 246: 01065.
- [24] Meng X, Chang J, Wang X, et al. Multi-objective hydropower station operation using an improved cuckoo search algorithm[J]. Energy, 2019, 168: 425-439.
- [25] Fang R, Popole Z. Multi-objective optimized scheduling model for hydropower reservoir based on improved particle swarm optimization algorithm[J]. Environmental Science and Pollution Research, 2020, 27: 12842-12850.
- [26] Marcelino C G, Camacho-Gómez C, Jiménez-Fernández S, et al. Optimal generation scheduling in hydro-power plants with the coral reefs optimization algorithm[J]. Energies, 2021, 14(9): 2443.
- [27] Feng Z K, Niu W J, Zhou J Z, et al. Multiobjective operation optimization of a cascaded hydropower system[J]. Journal of Water Resources Planning and Management, 2017, 143(10): 05017010.
- [28] Marcelino C G, Leite G M C, Delgado C A D M, et al. An efficient multi-objective evolutionary

- approach for solving the operation of multi-reservoir system scheduling in hydro-power plants[J]. Expert Systems with Applications, 2021, 185: 115638.
- [29] Chen Y, Wang M, Zhang Y, et al. Cascade hydropower system operation considering ecological flow based on different multi-objective genetic algorithms[J]. Water Resources Management, 2023: 1-18.
- [30] Wang P, Yuan W, Su C, et al. Short-term optimal scheduling of cascade hydropower plants shaving peak load for multiple power grids[J]. Renewable Energy, 2022, 184: 68-79.
- [31] 肖人彬, 李贵, 陈峙臻. 进化超多目标优化研究进展及展望[J]. 控制与决策, 2023, 38(7): 1761-1788.
- [32] Chen H, Wagner D. MOPS: an infrastructure for examining security properties of software[C]//Proceedings of the 9th ACM Conference on Computer and Communications Security. 2002: 235-244.
- [33] Greco S, Matarazzo B, Slowinski R. Rough approximation of a preference relation by dominance relations[J]. European Journal of operational research, 1999, 117(1): 63-83.
- [34] Deng W, Zhang X, Zhou Y, et al. An enhanced fast non-dominated solution sorting genetic algorithm for multi-objective problems[J]. Information Sciences, 2022, 585: 441-453.
- [35] Riquelme N, Von Lücken C, Baran B. Performance metrics in multi-objective optimization[C]//2015 Latin American computing conference (CLEI). IEEE, 2015: 1-11.
- [36] Shang K, Ishibuchi H, He L, et al. A survey on the hypervolume indicator in evolutionary multiobjective optimization[J]. IEEE Transactions on Evolutionary Computation, 2020, 25(1): 1-20.
- [37] Ishibuchi H, Masuda H, Tanigaki Y, et al. Modified distance calculation in generational distance and inverted generational distance[C]//Evolutionary Multi-Criterion Optimization: 8th International Conference, EMO 2015, Guimarães, Portugal, March 29--April 1, 2015. Proceedings, Part II 8. Springer International Publishing, 2015: 110-125.
- [38] Riquelme N, Von Lücken C, Baran B. Performance metrics in multi-objective optimization[C]//2015 Latin American computing conference (CLEI). IEEE, 2015: 1-11.
- [39] Ackermann T, Loucks D P, Schwanenberg D, et al. Real-time modeling for navigation and hydropower in the river Mosel[J]. Journal of Water Resources Planning and Management, 2000, 126(5): 298-303.
- [40] Tirkolaee E B, Goli A, Hematian M, et al. Multi-objective multi-mode resource constrained project

- scheduling problem using Pareto-based algorithms[J]. Computing, 2019, 101: 547-570.
- [41] Alberg D, Last M. Short-term load forecasting in smart meters with sliding window-based ARIMA algorithms[J]. Vietnam Journal of Computer Science, 2018, 5: 241-249.
- [42] Chen Y, Xu P, Chu Y, et al. Short-term electrical load forecasting using the Support Vector Regression (SVR) model to calculate the demand response baseline for office buildings[J]. Applied Energy, 2017, 195: 659-670.
- [43] Xu L, Li C, Xie X, et al. Long-short-term memory network based hybrid model for short-term electrical load forecasting[J]. Information, 2018, 9(7): 165.
- [44] Bejarano G, Kulkarni A, Raushan R, et al. Swap: Probabilistic graphical and deep learning models for water consumption prediction[C]//Proceedings of the 6th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation. 2019: 233-242.
- [45] Goldstein N C, Newmark R L, Whitehead C D, et al. The energy-water nexus and information exchange: Challenges and opportunities[J]. International Journal of Water, 2008, 4(1-2): 5-24.
- [46] Smola A J, Schölkopf B. A tutorial on support vector regression[J]. Statistics and computing, 2004, 14: 199-222.
- [47] Shumway R H, Stoffer D S, Shumway R H, et al. ARIMA models[J]. Time series analysis and its applications: with R examples, 2017: 75-163.
- [48] Alzubaidi L, Zhang J, Humaidi A J, et al. Review of deep learning: Concepts, CNN architectures, challenges, applications, future directions[J]. Journal of big Data, 2021, 8: 1-74.
- [49] Yu Y, Si X, Hu C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.
- [50] Dey R, Salem F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]//2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS). IEEE, 2017: 1597-1600.
- [51] Lu W, Li J, Li Y, et al. A CNN-LSTM-based model to forecast stock prices[J]. Complexity, 2020, 2020: 1-10.
- [52] Sajjad M, Khan Z A, Ullah A, et al. A novel CNN-GRU-based hybrid approach for short-term residential load forecasting[J]. Ieee Access, 2020, 8: 143759-143768.
- [53] Knowles J D. Local-search and hybrid evolutionary algorithms for Pareto optimization[D]. University

- of Reading, 2002.
- [54] Jia T, Zhou J, Liu X. A daily power generation optimized operation method of hydropower stations with the navigation demands considered[C]//MATEC Web of Conferences. EDP Sciences, 2018, 246: 01065.
- [55] Song H, Ding Z, Guo C, et al. Research on combination kernel function of support vector machine[C]//2008 International conference on computer science and software engineering. IEEE, 2008, 1: 838-841.
- [56] Zhong S, Chen D, Xu Q, et al. Optimizing the Gaussian kernel function with the formulated kernel target alignment criterion for two-class pattern classification[J]. Pattern Recognition, 2013, 46(7): 2045-2054.
- [57] Lin H T, Lin C J. A study on sigmoid kernels for SVM and the training of non-PSD kernels by SMO-type methods[J]. Neural Comput, 2003, 3(1-32): 16.
- [58] Prajapati G L, Patle A. On performing classification using SVM with radial basis and polynomial kernel functions[C]//2010 3rd International Conference on Emerging Trends in Engineering and Technology. IEEE, 2010: 512-515.
- [59] Marmolin H. Subjective MSE measures[J]. IEEE transactions on systems, man, and cybernetics, 1986, 16(3): 486-489.
- [60] Willmott C J, Matsuura K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance[J]. Climate research, 2005, 30(1): 79-82.
- [61] Chai T, Draxler R R. Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature[J]. Geoscientific model development, 2014, 7(3): 1247-1250.
- [62] Chicco D, Warrens M J, Jurman G. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation[J]. PeerJ Computer Science, 2021, 7: e623.
- [63] Nakagawa S, Schielzeth H. A general and simple method for obtaining R² from generalized linear mixed-effects models[J]. Methods in ecology and evolution, 2013, 4(2): 133-142.
- [64] Wu G, Niu D. A study of carbon peaking and carbon neutral pathways in China's power sector under a 1.5° C temperature control target[J]. Environmental Science and Pollution Research, 2022, 29(56): 85062-85080.

- [65] Hong Z, Su H, Liu H, et al. Research on key technologies and business models of low-carbon transformation of power industry under the “double carbon” trend[C]//2021 11th International Conference on Power and Energy Systems (ICPES). IEEE, 2021: 643-647.
- [66] Yan L, Wang J, Yang K. Grid-Connection Control of Small Hydropower Stations Based on the Principle of Quasi-Contemporaneous Grid-Connected[C]//Big Data Analytics for Cyber-Physical System in Smart City: BDCPS 2020, 28-29 December 2020, Shanghai, China. Springer Singapore, 2021: 1444-1451.
- [67] Giudicianni C, Mitrovic D, Wu W, et al. Energy recovery strategies in water distribution networks: literature review and future directions in the net-zero transition[J]. Urban Water Journal, 2023: 1-16.
- [68] Yang Y, Gao W, Guo S, et al. Introduction to BeiDou-3 navigation satellite system[J]. Navigation, 2019, 66(1): 7-18.
- [69] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.
- [70] Mirjalili S. Evolutionary algorithms and neural networks[M]//Studies in computational intelligence. Berlin/Heidelberg, Germany: Springer, 2019, 780.
- [71] Poli R, Kennedy J, Blackwell T. Particle swarm optimization: An overview[J]. Swarm intelligence, 2007, 1: 33-57.
- [72] Almufti S M, Ahmad H B, Marqas R B, et al. Grey wolf optimizer: Overview, modifications and applications[J]. International Research Journal of Science, Technology, Education, and Management, 2021, 1(1): 1-1.
- [73] Rashedi E, Rashedi E, Nezamabadi-Pour H. A comprehensive survey on gravitational search algorithm[J]. Swarm and evolutionary computation, 2018, 41: 141-158.
- [74] Cheng R, Jin Y, Olhofer M, et al. A reference vector guided evolutionary algorithm for many-objective optimization[J]. IEEE Transactions on Evolutionary Computation, 2016, 20(5): 773-791.
- [75] Yang X S, He X. Nature-inspired optimization algorithms in engineering: overview and applications[J]. Nature-inspired computation in engineering, 2016: 1-20.
- [76] Udalov F E. A Centralized Management System, Good or Bad?[J]. problems of economic transition, 2014, 57(6): 50-55.

- [77] Shin D D H. Blockchain: The emerging technology of digital trust[J]. Telematics and informatics, 2019, 45: 101278.
- [78] B. Rawat D, Chaudhary V, Doku R. Blockchain technology: Emerging applications and use cases for secure and trustworthy smart systems[J]. Journal of Cybersecurity and Privacy, 2020, 1(1): 4-18.